



Relatório Final · Desafio Quant AI 2026 (Itaú Asset)

Por que CORO? Numa earnings call, os executivos formam um coro que ensaia uma mensagem única. O robô mede o desalinhamento dessas vozes, a Tone Distance (TD). Quando o coro desafina, há informação.

33.362 calls · 685 empresas · S&P 500, 2005–2025 · dois sensores de tom (dicionário LM e FinBERT)

A tese de investimento

A divergência de tom entre os gestores da mesma call é informação precificada, em dois tempos: o mercado penaliza no anúncio e paga prêmio a quem carrega a empresa divergente depois.

$t = -2,8$

O anúncio

Empresas cujos gestores divergem sofrem retorno anormal menor no dia (painel com efeitos fixos, 23,6 mil eventos; confirmado nos dois sensores).

+20,4% a.a.

A carteira


Top-10 por TD, rebalanceada todo mês, contra +13,2% do S&P 500 em 199 meses (fev/2009 a ago/2025), líquida de custos: +19,4%.

$t = +3,58$

O aviso

A TD de hoje antecipa a magnitude da surpresa do próximo lucro (fora da amostra, 71% de acerto): termômetro de incerteza pré-anúncio.

O relatório também documenta o que reprovou: a hipótese de risco caiu na validação temporal e foi descartada.



O detalhe que virou o sinal: como definir o centro da call

Na média simples, cada orador pesa igual: numa call da Apple (2020), um orador de 283 palavras, cujas únicas 6 negativas eram o aviso legal, pesava 1/3 do sinal. **Ponderar pelo volume de fala separa sinal de ruído** e é o que faz a hipótese aparecer (Seção de resultados). Implementação verificada por reimplementação independente nas 32.387 calls elegíveis (diferença máxima $\sim 10^{-16}$).



Três hipóteses registradas antes dos testes

H1 • precificação

maior TD, menor o retorno anormal no anúncio

CONFIRMADA

H3 • incerteza

maior TD, mais imprevisível o próximo resultado

CONFIRMADA

H2 • risco

maior TD, maior a volatilidade futura

DESCARTADA

Estatística t da TD sobre o CAR do anúncio (janelas 1/2/5 pregões)

construção do sinal	LM (dicionário)	FinBERT (neural)
centro = média simples	-0,7 / -0,7 / -0,4	+0,1 / -0,3 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,8 / -2,7 / -2,3	-2,3 / -2,4 / -2,5

Como ler: a hipótese confirma quando o sinal respeita o volume de fala; o enfraquecimento de baixo para cima mostra o custo de dar peso a oradores marginais. Dois sensores que concordam em só 38% chegam ao mesmo desenho. Efeito: 0,11% a 0,16% por variação interquartil.

- **Retornos subsequentes:** o retorno dos 3 meses após a call cresce com a TD ($t=+2,0$ nos dois sensores). O mercado penaliza no anúncio e cobra prêmio para carregar: compensação por risco.
- **H3, o resultado preditivo mais forte:** |surpresa| do próximo lucro cresce com a TD ($t=+2,5$ no painel; $t=+3,58$ fora da amostra, 71% de acerto em 49 trimestres).
- **Robustez temporal:** reestimando só com o passado em cada corte, H1 mantém sinal negativo em todos; previsão fora da amostra $t=-2,12$, negativa em cada ano de 2019 a 2025.

Por que descartamos a H2 (e por que isso valida o método)

- **A associação existe na amostra cheia ($t=+2,5$), mas é eco:** janelas de volatilidade que começam no dia +1 ainda contêm a reação ao próprio anúncio, que é a H1. Fora do eco, $t=+1,3$.
- **Nenhuma das 16 especificações predefinidas prevê** (com/sem eco, 2 horizontes, nível/log, 2 construções); fora da amostra, $t=+0,27$. A TD não diz sobre risco nada que a vol passada não diga.
- **O mesmo protocolo que valida H1 e H3 reprovava a H2:** o critério não é complacente. Em amostra cheia as três pareciam certas; só a validação temporal separou efeito real de artefato.

	Top-10 TD bruto	Top-10 líquido	Bottom-10	Universo EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

199 meses (fev/2009 a ago/2025) · giro médio 35%/mês · composições verificáveis

- **Contra o S&P 500:** +7,1% a.a. (t=2,60), vitória em 58% dos meses e 11 de 17 anos.
- **Contra a régua justa** (universo elegível em pesos iguais): +3,6% a.a. (t=1,59), positivo em todos os subperíodos; sem significância isolada porque 10 ativos concentram ruído.
- **Cenários:** brilha em estresse e recuperação (2018: +0,4% vs -6,2%; 2022: -14,1% vs -19,4%); fica atrás em altas amplas (2016, 2021).
- **Sharpe 1,01 vs 0,99 do universo:** o retorno extra remunera risco extra. Prêmio de compensação, não anomalia gratuita.

Defesas contra vieses (por construção, não por promessa)

- **Look-ahead:** os scripts auditam, mês a mês, que nenhuma call usada é posterior ao início do mês investido; fundamentos entram pela data de protocolo; calls pós-fechamento (26%) ancoradas no pregão seguinte.
- **Overfitting:** especificação do long-short congelada antes de rodar; período completo 2006–2025 sem seleção; todas as 6 construções contadas para ajuste de múltiplos testes (Deflated Sharpe); hipóteses registradas antes dos testes.
- **Sobrevivência:** universo inclui as empresas que saíram do índice; a limitação restante (~3 mil eventos sem preço de deslistadas) é declarada.
- **Long-short por quintis (contraprova):** não monetiza (melhor Sharpe 0,22 vs 0,53 do mercado): a ponta FinBERT embute fator de baixa vol; por isso a proposta é tilt comprado, não long-short.

GenAI aplicada, com validação e custo

- **No núcleo do pipeline (código e dados):** um LLM via linha de comando (claude -p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes (~4,6h), com cache versionado e reprocessamento determinístico.
- **Validação do uso:** matriz de confusão contra 292 rótulos manuais (90% de acerto) e classificador determinístico independente (99% de concordância nos casos frequentes); prompt e custos documentados.
- **Par de engenharia e auditoria:** o assistente apoiou arquitetura, código, testes e a auditoria da fórmula do centro da call; decisões econômicas sempre da equipe.
- **Honestidade conceitual:** o FinBERT é modelo encoder de classificação: contabilizado como NLP/ML, não como IA generativa.

O que aprendemos e para onde vamos

- **Aprendizado central:** em amostra completa, as três hipóteses pareciam confirmadas; foi a robustez temporal que separou os efeitos reais (H1, H3, prêmio) do artefato (H2). Validar no tempo é o ativo metodológico do projeto.
- **A tese que fica:** divergência de tom é precificada em dois tempos: penalidade no anúncio e prêmio de compensação depois (+20,4% vs +13,2% a.a.), com o mesmo score antecipando a surpresa do próximo lucro.
- **Próximos passos:** integração multifator do score com Deflated Sharpe; diversificação além de 10 nomes, sensibilidade a custos e decaimento; small/mid caps com o pré-registro já versionado (teste piloto inconclusivo por potência; efeito segue nas large caps no mesmo período, $t=-1,96$).

Reprodutibilidade: todos os números saem de scripts versionados, reproduzidos em clone limpo e revalidados na data da entrega; nenhum número digitado à mão. Código, dados e documentação à disposição da banca mediante solicitação.

Referências essenciais: Angelo, Johnston, Singh e Wan (2025, The Financial Review); Loughran e McDonald (2011, JF); Huang, Teoh e Zhang (2014, TAR); Lee (2016, TAR); Yang, Uy e Huang (2020, FinBERT); Bailey e López de Prado (2014, JPM); Fama e French (1997, JFE).