



CORO: Divergência de tom entre gestores como sinal quantitativo de investimento

Relatório Final · Desafio Quant AI 2026 (Itaú Asset)

O nome CORO resume a estratégia: numa earnings call, os executivos formam um coro que ensaia uma mensagem única, e o robô mede o desalinhamento dessas vozes. Quando o coro desafina, há informação.

Sumário executivo

Este relatório apresenta a construção e a validação de um sinal quantitativo extraído das teleconferências de resultados: a divergência de tom entre os executivos de uma mesma empresa, medida pela Tone Distance (TD). Foram processadas 33.362 transcrições de 685 empresas do S&P 500 (2005 a 2025), e os testes em painel confirmam a tese: empresas cujos gestores divergem mais sofrem retorno anormal menor no anúncio (t até $-2,8$), rendem mais nos três meses seguintes ($t=+2,0$) e entregam surpresas de lucro mais imprevisíveis no trimestre posterior ($t=+3,58$ fora da amostra, o resultado preditivo mais forte). O quadro se repete em dois medidores de tom independentes, o que afasta artefato de instrumento.

Na implementação, a carteira que compra mensalmente as 10 empresas de maior TD rendeu $+20,4\%$ ao ano contra $+13,2\%$ do S&P 500 em 199 meses (fev/2009 a ago/2025). O relatório também documenta o que não funcionou: a hipótese de que o sinal prevê volatilidade futura caiu nos testes de robustez e foi descartada, decisão detalhada por evidenciar o rigor do processo. Todos os resultados se reproduzem do repositório do projeto com quatro comandos (código e dados à disposição da banca mediante solicitação).

1. Contexto, problema e identidade do robô

Quem acompanha earnings calls conhece a cena: o CEO abre com a mensagem preparada e, no Q&A, cada executivo responde com o tom que consegue sustentar ao vivo. O texto é coordenado; o tom, nem sempre. A premissa do trabalho é que esse descompasso carrega informação: um CFO visivelmente mais cauteloso que o CEO na mesma call sinaliza desacordo interno ou incerteza que nenhum press release admitiria. Daí as duas perguntas da pesquisa: é possível medir essa divergência de forma sistemática? E, medida, ela tem valor econômico?

Dessas perguntas derivam as três hipóteses, registradas antes dos testes:

- H1 (precificação): maior divergência de tom, menor o retorno anormal na janela do anúncio.
- H2 (risco): maior divergência, maior a volatilidade realizada após o anúncio.
- H3 (operacional): maior divergência, mais imprevisível o resultado do trimestre seguinte.

O CORO é a resposta prática: lê a transcrição de cada call, atribui cada fala ao seu orador, mede o tom de cada gestor e resume o desalinhamento em um score por empresa-trimestre, pronto minutos após a publicação da transcrição. Para a mesa, é insumo no mesmo dia do evento: sinal de seleção, condicionante de exposição a anúncios e termômetro de incerteza. A identidade visual traduz o mecanismo: o robô ouvinte, de fones, diante de vozes que chegam alinhadas e uma que desafina.



2. Referencial teórico

A literatura de finanças textuais estabelece que o tom da comunicação corporativa move preços: Loughran e McDonald (2011) construíram o dicionário de tom para finanças; Huang, Teoh e Zhang (2014) mostraram que gestores administram o tom e que o mercado reage ao seu componente anormal; Lee (2016) documentou que investidores penalizam executivos presos a roteiros. A medida deste trabalho vem de Angelo, Johnston, Singh e Wan (2025), que deslocam a pergunta do tom médio para a divergência entre os executivos da mesma call, a Tone Distance. Partindo dessa referência, realizamos um teste independente, com universo, dados e código próprios, e uma extensão deliberada: toda a análise foi refeita trocando o medidor de tom pelo FinBERT (Yang, Uy e Huang, 2020), modelo neural que classifica cada sentença pelo contexto. A troca é a contraprova do instrumento: fenômeno real aparece nos dois medidores.

3. Dados e construção do sinal

A amostra reúne 33.362 transcrições de empresas que integraram o S&P 500 entre 2005 e 2025 (dataset público kurry/HuggingFace, 685 empresas, incluindo as que saíram do índice). Preços vêm do Yahoo Finance; fundamentos, do SEC EDGAR alinhados pela data de protocolo, sem antecipação de informação; setores seguem Fama e French (1997). Para separar gestores de analistas e operadores, um classificador em dois níveis (LLM via linha de comando mais regras determinísticas) tratou os 12.678 cabeçalhos de orador da base, com cerca de 90% de acerto auditado contra 292 rótulos manuais.

O cálculo do sinal tem três passos: cada gestor i vira um vetor $g(i) = (p(i), n(i))$ com as frações de linguagem positiva e negativa da sua fala; calcula-se o centro c da call; e a TD é a média das distâncias euclidianas ao centro, $TD = (1/N) \sum \|g(i) - c\|$, exigindo ao menos dois gestores. A definição do centro rendeu a principal contribuição metodológica. Na média simples cada orador pesa igual, e numa call da Apple de 2020 um orador de 283 palavras, cujas únicas 6 negativas eram o aviso legal padrão, respondia por um terço do sinal. O tom agregado (cada palavra pesa igual) corrige a contaminação, e a ponderação pelo volume de fala leva a correção ao limite; a Seção 5 mostra que o sinal enfraquece conforme se devolve peso a oradores marginais. A implementação foi verificada por reimplementação independente nas 32.387 calls elegíveis (diferença máxima da ordem de 10^{-16}).

4. Método de teste

O retorno anormal acumulado (CAR) é a diferença entre o retorno observado e o previsto pelo CAPM, acumulada nas janelas de 1, 2 e 5 pregões ao redor do anúncio, com beta estimado em 100 pregões separados do evento; calls após o fechamento (26% da amostra) são ancoradas no pregão seguinte. O teste central é um painel com efeitos fixos de empresa e trimestre, controles de tamanho, valor, alavancagem, rentabilidade, surpresa, momentum e reversão, erros agrupados por empresa e winsorização em 5/95. O efeito fixo importa para a leitura: compara-se a Apple de um trimestre com a própria Apple típica, não a Apple com a Exxon. Reportamos sempre a estatística t ; pela convenção usual, valores acima de 2 em módulo indicam significância a 5%.

Na implementação, dois backtests independentes, ambos com custos e com auditoria, nos próprios scripts, de que nenhuma informação futura entra na seleção. O primeiro compra, ao fim de cada mês, as 10 empresas de maior TD em pesos iguais (call mais recente dos três meses anteriores), carrega por um mês e rebalanceia, a 10 pontos-base por lado sobre o giro. O segundo é um long-short por quintis calendar-time com especificação congelada antes da execução (entrada no pregão seguinte à call, 63 pregões de manutenção, custos de 5 pontos-base por perna, 2006 a 2025). As defesas contra vieses são explícitas: contra look-ahead, a auditoria automática de datas e o alinhamento de fundamentos pela data de protocolo; contra overfitting, a

especificação congelada antes da execução, o período completo sem seleção e a contagem de todas as tentativas para ajuste de múltiplos testes; contra sobrevivência, o universo com as empresas que saíram do índice. Todos os números saem de scripts versionados; a replicação exige quatro comandos e foi testada em clone limpo, com resultados idênticos.

5. Resultados econométricos

A base reconstruída é comparável à da literatura: a distribuição da TD (média 0,0086, mediana 0,0080, desvio 0,0047) fica próxima da referência (0,0079, 0,0074, 0,0048), e os controles batem com os publicados.

5.1 H1, precificação no anúncio: confirmada

A tabela reporta as estatísticas t da TD sobre o CAR nas três janelas, para as três construções do sinal e os dois medidores (2009 em diante, cerca de 23,6 mil eventos):

construção do sinal	LM (dicionário)	FinBERT (neural)
centro = média simples	-0,7 / -0,7 / -0,4	+0,1 / -0,3 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,8 / -2,7 / -2,3	-2,3 / -2,4 / -2,5

Três conclusões saem da tabela. A hipótese confirma-se quando o sinal respeita o volume de fala (a ponderada é significativa em todas as janelas e medidores; a agregada, na maior parte). O enfraquecimento de baixo para cima é gradual: quanto mais peso ao ruído dos oradores marginais, mais o sinal se dilui. E dois medidores que concordam entre si em apenas 38% chegam ao mesmo desenho. Em termos econômicos, pular do quartil inferior ao superior da TD custa entre 0,11% e 0,16% de retorno no anúncio.

5.2 Retornos subsequentes: confirmados

Em painel mensal, o retorno dos três meses seguintes cresce com a TD ($t=+2,0$ nos dois medidores), com controles de valor, momentum, tamanho e reversão. Junto com a H1, o desenho fecha: o mercado penaliza no anúncio e cobra prêmio para carregar a empresa divergente, o padrão clássico de compensação por risco.

5.3 H3, incerteza operacional: confirmada

A magnitude da surpresa de lucro do trimestre seguinte cresce com a TD ($t=+2,5$ no painel). Na previsão fora da amostra, com modelo treinado só no passado, a relação alcança $t=+3,58$ e acerto direcional em 71% dos trimestres, o resultado preditivo mais forte do projeto: a divergência de hoje avisa que o próximo balanço tende a vir com surpresa grande.

5.4 H2, risco: descartada como sinal

Na amostra completa existe associação entre TD e volatilidade futura ($t=+2,5$ no dicionário). A investigação, porém, revelou um vício de medição: janelas que começam no dia seguinte ao anúncio ainda carregam a reação ao próprio anúncio, e empresas de TD alta reagem mais (a H1). Fora desse eco, a associação perde significância ($t=+1,3$), e nenhuma das 16 especificações predefinidas mostrou poder de previsão. A TD não informa sobre risco futuro nada que a volatilidade passada já não diga; o canal foi descartado. Permanece verdadeiro, como descrição, que empresas de TD alta são mais voláteis, o que retorna na interpretação do backtest.

5.5 Robustez temporal

Reestimando tudo apenas com os dados disponíveis até cada data de corte, o coeficiente da H1 mantém o sinal negativo em todos os cortes, e a previsão fora da amostra confirma ($t=-2,12$, negativa em cada ano de 2019 a 2025); a camada de retornos mantém coeficiente positivo em todos os cortes; a H3 sustenta o $t=+3,58$. A exceção é a H2, reprovada ($t=+0,27$), o que motivou o descarte. O mesmo protocolo que valida duas hipóteses reprovava a terceira: o critério não é complacente.

6. Backtest

Resultados da carteira principal em 199 meses (fev/2009 a ago/2025); o Sharpe é o retorno em excesso por unidade de volatilidade, e o drawdown, a maior queda acumulada:

	Top-10 TD bruto	Top-10 TD líquido	Bottom-10 TD	Universo elegível EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

A leitura é feita em duas camadas. Contra o S&P 500, o excesso é de +7,1% ao ano ($t=2,60$), com vitória em 58% dos meses e em 11 dos 17 anos. Como carteiras de pesos iguais tendem a superar índices ponderados por valor, construiu-se a régua mais exigente, o próprio universo elegível em pesos iguais: contra ela, a seleção por TD adiciona +3,6% ao ano ($t=1,59$), positiva em todos os subperíodos (+1,8% de 2010 em diante; +2,6% de 2019 em diante), embora sem significância isolada, consequência esperada de concentrar em 10 ativos, nos quais o ruído específico domina. A carteira espelho (menor TD) rende 5,1 pontos menos ao ano. Quanto a cenários, o top-10 destaca-se em anos de estresse ou recuperação (fechou 2018 em +0,4% contra -6,2% do índice e caiu menos em 2022, -14,1% contra -19,4%) e fica para trás em altas amplas como 2016 e 2021. O giro médio é de 35% ao mês e as composições mês a mês são verificáveis no repositório do projeto.

O long-short por quintis não monetiza: retornos líquidos entre +0,3% e +4,4% conforme a construção, melhor Sharpe de 0,22 (estatisticamente nulo) contra 0,53 do mercado. O diagnóstico de pernas explica: correlação de só 0,6 entre as pontas, e o quintil alto do FinBERT embute exposição a baixa volatilidade, um fator, não tom. As 6 construções registradas entram no ajuste de múltiplos testes (Bailey e López de Prado, 2014).

O perfil de risco fecha a interpretação: o top-10 realiza volatilidade maior (20,6% contra 17,3%) e Sharpe próximo ao do universo (1,01 contra 0,99), ou seja, o retorno extra remunera risco extra, coerente com a Seção 5.4. A evidência sustenta quatro usos: tilt direcional sobre um portfólio core; condicionamento de exposição em torno de anúncios; posicionamento de volatilidade no próximo anúncio das empresas de divergência alta, apoiado na previsão de surpresa; e insumo em arcabouço multifator.

7. Riscos e limitações

Como toda pesquisa empírica, o trabalho tem limitações que preferimos declarar. Os papéis de orador foram reconstruídos por classificador próprio (cerca de 90% de acerto), ruído que as bases comerciais curadas não têm; algumas variáveis usam proxies (surpresa via Yahoo Finance em vez de I/B/E/S; dois dos 19 controles não reconstruídos); e cerca de 3 mil eventos ficaram sem CAR por falta de preços de deslistadas em fonte gratuita. Na implementação, o efeito no anúncio (cerca de 0,15% por variação interquartil) não paga custos como arbitragem isolada do evento, razão pela qual a proposta se concentra em tilt, condicionamento e volatilidade; e, com 10 ativos, o excesso sobre o universo em pesos iguais é consistente mas não significativo isoladamente, de modo que diversificar é o caminho natural de evolução. Por fim, o centro da call admite duas construções na literatura; reportamos ambas, e a escolha da agregada seguiu a evidência textual da referência e o diagnóstico de ruído da Seção 3, não o resultado.

8. Conclusão e próximos passos

O trabalho verificou se a divergência de tom entre gestores constitui informação precificada e se pode virar estratégia. As evidências apontam que sim: o fenômeno foi confirmado em universo independente, sobreviveu à troca completa do medidor de tom e se materializou em carteira implementável, com custos e auditoria de ausência de informação futura.

A tese de investimento cabe em um parágrafo. A divergência de tom é precificada em dois tempos: no anúncio, o mercado penaliza a empresa cuja diretoria diverge; nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação (+20,4% ao ano contra +13,2% do S&P 500 em 16 anos e meio), remunerando o risco que o próprio sinal identifica. O mesmo escore antecipa a magnitude da surpresa do lucro seguinte, servindo de termômetro de incerteza pré-anúncio. Registramos também a

fronteira que não avançou: em 2.250 firmas fora do S&P 500 (2019 a 2023), com pré-registro versionado, o painel saiu inconclusivo por potência; no mesmo período o efeito segue nas large caps ($t=-1,96$).

Como evolução, três caminhos: a integração multifator do escore, com contagem de tentativas e Deflated Sharpe; a diversificação além de 10 nomes, com sensibilidade a custos e análise de decaimento; e a revisita a small e mid caps havendo preços de deslistadas. Encerra-se com a nota de método que organiza o trabalho: em amostra completa, as três hipóteses pareciam confirmadas, e foi a robustez temporal que separou os efeitos reais do artefato. Esse protocolo, documentado no repositório, é o principal ativo metodológico da equipe.

9. Uso de IA generativa no processo

O uso de GenAI é operacional e auditável. No núcleo do pipeline, um processo por linha de comando (claude - p, modelo Haiku) classificou os 12.678 cabeçalhos de orador, com cache versionado e reproprocessamento determinístico (~4,6h), validado por matriz de confusão contra 292 rótulos manuais (cerca de 90% de acerto) e por classificador determinístico independente (99% de concordância nos casos frequentes); prompt, custos e validação estão em docs/GENAI_USAGE.md. Ao longo do projeto, o assistente (Claude) atuou como par de engenharia e auditoria, incluindo a auditoria da fórmula do centro da call, sempre com as decisões econômicas e metodológicas a cargo da equipe. O FinBERT, modelo encoder de classificação, é contabilizado como NLP/ML, não como IA generativa.

Referências

Angelo, Johnston, Singh e Wan (2025). Tone Distance: Managerial Tone Divergence and Market Reaction to Earnings. *The Financial Review*.

Bailey, D. H., e López de Prado, M. (2014). The Deflated Sharpe Ratio. *The Journal of Portfolio Management*, 40(5).

Fama, E. F., e French, K. R. (1997). Industry Costs of Equity. *Journal of Financial Economics*, 43(2).

Huang, X., Teoh, S. H., e Zhang, Y. (2014). Tone Management. *The Accounting Review*, 89(3).

Lee, J. (2016). Can Investors Detect Managers' Lack of Spontaneity? *The Accounting Review*, 91(1).

Loughran, T., e McDonald, B. (2011). When Is a Liability Not a Liability? *The Journal of Finance*, 66(1).

Yang, Y., Uy, M. C. S., e Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. arXiv:2006.08097.

Todos os números deste relatório saem de scripts versionados, foram reproduzidos em clone limpo e revalidados na data da entrega. Nenhum número foi digitado à mão. Código, dados e documentação completa ficam à disposição da banca mediante solicitação.