

CORO: Divergência de tom entre gestores como sinal quantitativo de investimento

Pré-relatório · Desafio Quant AI 2026 (Itaú Asset)

Equipe: Marcelo e Caio · Orientação: Profa. Nadia Cardoso Moreira

Repositório com código, dados e replicação completa:

<https://github.com/marceleann/Caio-e-Marcelo-e-Vinicius>

Nome do robô em definição pela equipe (alternativas em avaliação: DESAFINADO, DISSONA, OUVIDOR, CORO). O conceito é único: o robô não mede o tom médio da empresa, e sim o desalinhamento entre as vozes que a representam.

Sumário executivo

Toda earnings call é uma peça ensaiada, mas quem a executa são pessoas. Este trabalho parte de uma observação simples: quando os executivos da mesma empresa divergem no tom ao falar do mesmo trimestre, essa divergência carrega informação que a mensagem oficial não entrega. Nós transformamos essa observação em um sinal quantitativo, a Tone Distance (TD), calculada minutos após a divulgação de cada transcrição, e a testamos de ponta a ponta em 33.362 teleconferências de 685 empresas do S&P 500, entre 2005 e 2025.

Os resultados sustentam a tese. Nos testes econométricos, empresas cujos gestores divergem mais sofrem retorno anormal menor no dia do anúncio, entregam retornos maiores nos três meses seguintes e apresentam surpresas de lucro mais imprevisíveis no trimestre posterior; este último é o nosso resultado preditivo mais forte. O mesmo quadro aparece em dois medidores de tom independentes, o dicionário Loughran-McDonald e o modelo neural FinBERT, o que afasta a hipótese de o achado ser um artefato do instrumento de medida.

Na implementação, uma carteira que compra todo mês as 10 empresas de maior TD rendeu +20,4% ao ano, contra +13,2% do S&P 500, ao longo de 199 meses (fevereiro de 2009 a agosto de 2025), com excesso estatisticamente significativo e vitória em 13 dos 17 anos. O relatório também documenta o que não funcionou: a hipótese de que o sinal prevê volatilidade futura não passou nos testes de robustez e foi descartada, decisão que descrevemos em detalhe porque ela atesta o rigor do processo. Todos os resultados são reproduzíveis a partir do repositório público com quatro comandos.

1. Contexto e problema

Quem acompanha teleconferências de resultados conhece a cena. O CEO abre com a mensagem preparada, o CFO percorre os números e, quando começa a sessão de perguntas e respostas, cada executivo responde com o tom que consegue sustentar ao vivo. O texto é coordenado; o tom, nem sempre. Coordenar a narrativa entre quatro ou cinco oradores é viável; coordenar o otimismo de cada um, frase a frase, sob pergunta de analista, é consideravelmente mais difícil.

A premissa deste trabalho é que esse descompasso é informativo. Se o CFO soa visivelmente mais cauteloso que o CEO na mesma call, o mercado tem diante de si um indício de desacordo interno ou

de incerteza sobre o trimestre que nenhum press release admitiria. O problema de pesquisa se enuncia, então, em duas perguntas: é possível medir essa divergência de forma sistemática? E, se sim, ela tem valor econômico?

Dessas perguntas derivam as três hipóteses do estudo, registradas antes da execução dos testes:

- H1 (precificação): quanto maior a divergência de tom em uma call, menor o retorno anormal da empresa na janela do anúncio.
- H2 (risco): quanto maior a divergência, maior a volatilidade realizada da ação no período posterior ao anúncio.
- H3 (operacional): quanto maior a divergência, mais imprevisível o resultado operacional do trimestre seguinte.

O produto que materializa a resposta é o robô. Ele processa a transcrição de cada call, atribui cada fala ao seu orador, mede o tom de cada gestor e resume o desalinhamento em um único escore por empresa-trimestre, disponível minutos após a publicação da transcrição. Para uma mesa de gestão, isso significa um insumo utilizável no mesmo dia do evento: como sinal de seleção de ativos, como condicionante de exposição em torno de anúncios e como indicador antecedente de incerteza de resultados.

2. Referências

A ideia de que o tom da comunicação corporativa move preços tem lastro sólido na literatura de finanças textuais. Loughran e McDonald (2011) mostraram que dicionários genéricos de sentimento classificam mal a linguagem de negócios (termos como liability são negativos no uso comum e neutros em finanças) e construíram o dicionário específico que se tornou o padrão da área. Huang, Teoh e Zhang (2014) documentaram que gestores administram ativamente o tom de suas divulgações e que o mercado reage ao componente anormal desse tom. Lee (2016) mostrou que investidores percebem quando executivos abandonam a espontaneidade e se apegam a roteiros durante earnings calls, e penalizam essa rigidez.

O passo que origina a nossa medida é de Angelo, Johnston, Singh e Wan (2025). Em vez de perguntar qual é o tom médio da empresa, pergunta central da literatura anterior, os autores perguntam quanto os executivos da mesma call divergem entre si, e batizam a medida de Tone Distance. O argumento econômico é o descrito na Seção 1: a mensagem é ensaiada, mas a coordenação fina do tom entre vários oradores em tempo real é custosa, de modo que a divergência funciona como vazamento de informação privada.

Nosso trabalho toma essa referência como ponto de partida e a submete a um teste independente, com universo, dados e código integralmente próprios. E adiciona uma extensão deliberada: repetimos toda a análise trocando o medidor de tom, do dicionário para o FinBERT (Yang, Uy e Huang, 2020), um modelo de linguagem neural treinado especificamente em textos financeiros, que classifica cada sentença como positiva, negativa ou neutra a partir do contexto, e não de palavras isoladas. A lógica da extensão é a de validação cruzada de instrumento: se o fenômeno é real, deve aparecer nos dois medidores; se é artefato do dicionário, a troca o elimina.

3. Desenvolvimento: do texto bruto ao sinal

A matéria-prima são 33.362 transcrições de calls de empresas que integraram o S&P 500 entre 2005 e 2025 (dataset público kurry/ HuggingFace, 685 empresas, incluindo as que saíram do índice, o que reduz o viés de sobrevivência). Preços vêm do Yahoo Finance; fundamentos trimestrais, do SEC EDGAR, alinhados pela data de protocolo para que nenhuma informação seja usada antes de existir publicamente; a classificação setorial segue Fama e French (1997); a taxa livre de risco é a da base de Kenneth French.

O primeiro desafio prático é saber quem fala. Cada transcrição traz milhares de falas, e o sinal exige separar gestores de analistas e operadores. Resolvemos com um classificador em dois níveis: um modelo de linguagem via linha de comando classificou os 12.678 cabeçalhos de orador distintos da base, e regras determinísticas cobrem o restante. A classificação foi auditada contra 292 rótulos manuais, com cerca de 90% de acerto (o processo completo está descrito na Seção 9).

Com os papéis atribuídos, o sinal se constrói em três passos, que podem ser enunciados formalmente. Primeiro, cada gestor i da call é representado por um vetor $g(i) = (p(i), n(i))$, em que p e n são as frações de linguagem positiva e negativa de sua fala. Segundo, calcula-se o centro c da call. Terceiro, a Tone Distance é a média das distâncias euclidianas dos gestores ao centro: $TD = (1/N) \sum \|g(i) - c\|$. A medida vale zero quando todos os gestores soam idênticos e cresce à medida que as vozes se afastam. Exigimos no mínimo dois gestores por call, e cada fala é medida duas vezes, pelo dicionário e pelo FinBERT.

Um detalhe dessa construção acabou virando contribuição metodológica: a definição do centro c . Há duas leituras possíveis. Na média simples, c é a média dos vetores dos gestores, e cada orador pesa igual, independentemente de quanto falou. No tom agregado, c é o tom do texto completo da call, e cada palavra pesa igual. A diferença não é cosmética, e um exemplo real a ilustra. Em uma call da Apple de 2020, o profissional de relações com investidores falou apenas 283 palavras, e as únicas 6 classificadas como negativas pertenciam ao aviso legal padrão sobre riscos e incertezas; na média simples, esse orador marginal respondia por um terço do sinal da call inteira. O tom agregado, e além dele a ponderação explícita de cada gestor pelo seu volume de fala, elimina essa contaminação. Como se verá na Seção 5, os resultados enfraquecem monotonicamente à medida que se dá peso a oradores marginais, o que transforma o detalhe em diagnóstico: medir bem importa. A implementação foi verificada por reimplementação independente nas 32.387 calls elegíveis, com diferença máxima da ordem de 10^{-16} , e por exemplo auditável manualmente.

4. Método de teste

Dois conceitos sustentam toda a parte empírica e merecem definição explícita. O primeiro é o retorno anormal acumulado (CAR): a diferença entre o retorno observado da ação e o retorno que o CAPM previa dado o movimento do mercado, acumulada na janela do evento. Estimamos o beta de cada evento em uma janela de 100 pregões (mínimo de 70), separada do evento por 50 pregões para não contaminar a estimativa, e acumulamos o resíduo nas janelas de 1, 2 e 5 pregões ao redor do anúncio. Calls realizadas após o fechamento do mercado (27% da amostra) são ancoradas no pregão seguinte, respeitando o momento real em que a informação chegou ao investidor.

O segundo é o painel com efeitos fixos, a especificação central dos testes. A regressão inclui um intercepto próprio para cada empresa e para cada trimestre, além de controles de tamanho, valor,

alavancagem, rentabilidade, surpresa de lucro, momentum e reversão, com erros-padrão agrupados por empresa e winsorização em 5/95 (os 5% mais extremos de cada variável são truncados, prática padrão para conter outliers). O efeito fixo de empresa importa para a leitura econômica: o coeficiente não compara a Apple com a Exxon, compara a Apple de um trimestre com a própria Apple típica. O que se mede, portanto, é o efeito de a empresa divergir mais do que o seu padrão usual.

Sobre a convenção estatística: ao longo do relatório reportamos a estatística t de cada coeficiente, que expressa quantos erros-padrão o efeito estimado dista de zero. Pela convenção usual, valores acima de 2 em módulo indicam significância ao nível de 5%.

Para a implementação, desenhamos dois backtests independentes, ambos com custos de transação e com a garantia, auditada nos próprios scripts, de que nenhuma informação futura entra na seleção. O primeiro executa a tese da forma mais direta: ao fim de cada mês, compra em pesos iguais as 10 empresas de maior TD (usando a call mais recente dos três meses anteriores), carrega a posição por um mês e rebalanceia, pagando 10 pontos-base por lado sobre o giro. O segundo é um long-short por quintis: compra o quinto das empresas com maior TD e vende o quinto com menor, em formato calendar-time com tranches sobrepostas, especificação congelada antes da execução (entrada no pregão seguinte à call, manutenção de 63 pregões, ranking contra os 90 dias anteriores, custos de 5 pontos-base por perna, amostra 2006 a 2025).

Todos os números deste relatório saem de scripts versionados no repositório público. Um avaliador reproduz as regressões e os backtests com quatro comandos, sem reprocessar transcrições; o procedimento foi testado em clone limpo, com números idênticos.

5. Resultados econométricos

Antes das regressões, validamos a base reconstruída. A distribuição da nossa TD (média 0,0086, mediana 0,0080, desvio 0,0047) é aderente à da referência (0,0079, 0,0074, 0,0048), e os controles batem com os publicados: alavancagem 0,24 contra 0,235, alíquota efetiva mediana 0,22 contra 0,21, suavização de lucros 1,6 contra 1,4. Partimos, portanto, de uma base comparável à da literatura.

5.1 H1, precificação no anúncio: confirmada

A lógica do teste: se a divergência de tom revela informação negativa, o retorno anormal do anúncio deve cair com a TD, controlando por tudo o mais. A tabela reporta as estatísticas t do coeficiente da TD sobre o CAR, nas três janelas de evento, para as três construções do sinal e os dois medidores (amostra de 2009 em diante, cerca de 23 mil eventos e 540 empresas). Cada célula responde à pergunta: nesta forma de medir, a divergência derruba o retorno do anúncio?

construção do sinal	LM (dicionário)	FinBERT (neural)
centro = média simples	-0,7 / -0,6 / -0,3	+0,1 / -0,2 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,9 / -2,7 / -2,3	-2,4 / -2,4 / -2,5

(t nas janelas de 1, 2 e 5 pregões. Em termos econômicos, uma variação interquartil de TD, isto é, o salto do quartil inferior ao superior da medida, corresponde a algo entre 0,11% e 0,16% a menos de retorno anormal no anúncio.)

Três leituras. Primeira: a hipótese se confirma na amostra completa quando o sinal respeita o volume de fala de cada gestor (duas últimas linhas, todas significativas). Segunda: a progressão entre as linhas é monotônica; quanto mais peso ao ruído dos oradores marginais, mais fraco o sinal, exatamente o diagnóstico antecipado na Seção 3. Terceira: os dois medidores, cuja correlação entre si é de apenas 38%, contam a mesma história; o resultado não é artefato do instrumento.

5.2 Retornos subsequentes: confirmados

O efeito não termina no anúncio. Em painel mensal, regredimos o retorno dos três meses seguintes à call contra a TD, com efeitos fixos de empresa e mês e controles de valor, momentum, tamanho e reversão. O coeficiente é positivo e significativo nos dois medidores ($t=+2,1$ no dicionário; $+1,8$ no FinBERT). O quadro combinado com a H1 é economicamente coerente e familiar à teoria de apreçamento: o mercado penaliza a empresa divergente no ato e passa a exigir retorno maior para carregá-la, um prêmio de compensação pelo risco revelado.

5.3 H3, incerteza operacional: confirmada

A lógica do teste: se a divergência reflete incerteza interna sobre o negócio, ela deve antecipar surpresas de lucro maiores, em qualquer direção. Medimos a surpresa pelo valor absoluto do erro em relação à expectativa, e o coeficiente da TD é positivo no painel completo ($t=+2,2$). No exercício de previsão fora da amostra, em que o modelo é treinado apenas com dados passados e usado para prever eventos que ele nunca viu, a relação alcança $t=+3,58$, com acerto direcional em 71% dos trimestres: é o resultado preditivo mais forte do projeto. Em linguagem de mesa: a divergência de hoje avisa que o próximo balanço tende a vir com surpresa grande, para qualquer lado.

5.4 H2, risco: descartada como sinal

O caminho até o descarte merece registro, porque ilustra o método. Na amostra completa existe associação entre TD e volatilidade futura ($t=+2,5$ no dicionário). A investigação mostrou, porém, um problema de medição: janelas de volatilidade que começam no dia seguinte ao anúncio ainda contêm a própria reação ao anúncio, e empresas de TD alta reagem mais, que é justamente a H1. Quando a volatilidade é medida a partir do segundo dia, fora desse eco, a associação perde significância ($t=+1,3$). Nos testes de robustez, nenhuma das 16 especificações predefinidas (com e sem o eco, dois horizontes, nível e logaritmo, duas construções do sinal) mostrou poder de previsão. A conclusão: a TD não informa sobre risco futuro nada que a volatilidade passada já não diga, e o canal foi descartado como sinal. Permanece verdadeira a versão descritiva, a de que empresas de TD alta são em média mais voláteis, e esse fato retorna na interpretação do backtest.

5.5 Robustez e estabilidade temporal

Um resultado de amostra completa pode, em princípio, ser fruto de um único subperíodo favorável. Para excluir essa possibilidade, fizemos dois exercícios: reestimamos os modelos usando apenas os dados disponíveis até cada data de corte, conferindo o resultado no período posterior; e rodamos a previsão por evento fora da amostra já descrita. O coeficiente da H1 tem o mesmo sinal negativo em todos os cortes analisados, e a previsão fora da amostra confirma o efeito ($t=-2,12$, com resultado negativo em cada um dos anos de 2019 a 2025). A camada de retornos subsequentes mantém coeficiente positivo em todos os cortes, e a H3 sustenta o $t=+3,58$ citado. Nos primeiros anos, com menos dados acumulados, os intervalos de confiança são naturalmente mais largos, que é o comportamento esperado de um efeito estável estimado com precisão crescente, e não indício de

instabilidade. A exceção é a H2, reprovada nesses mesmos exercícios ($t=+0,27$), o que motivou o descarte. Vale o registro metodológico: o mesmo protocolo que valida duas hipóteses reprova a terceira, evidência de que o critério não é complacente.

6. Backtest

A implementação principal executa a tese da forma que um gestor reconheceria: carteira comprada, regra fixa, rebalanceamento mensal. Como referência de leitura: o índice de Sharpe é o retorno em excesso por unidade de volatilidade (quanto maior, melhor o retorno ajustado a risco), e o drawdown máximo é a maior queda acumulada do valor da carteira no período. Os números de 199 meses (fevereiro de 2009 a agosto de 2025):

	Top-10 TD bruto	Top-10 TD líquido	Bottom-10 TD	Universo elegível EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

ano	top-10 TD	bottom-10	universo EW	S&P 500
2009	+113,1%	+44,6%	+61,3%	+35,0%
2010	+19,2%	+10,1%	+23,1%	+12,8%
2011	+4,8%	+8,6%	+0,5%	-0,0%
2012	+39,3%	+24,6%	+20,2%	+13,4%
2013	+30,5%	+53,1%	+37,8%	+29,6%
2014	+10,3%	+5,8%	+15,6%	+11,4%
2015	+5,9%	+6,8%	-1,5%	-0,7%
2016	+6,2%	+15,5%	+17,6%	+9,5%
2017	+18,2%	+12,8%	+21,6%	+19,4%
2018	+0,4%	-14,5%	-7,2%	-6,2%
2019	+44,5%	+27,1%	+31,5%	+28,9%
2020	+11,8%	+2,7%	+15,8%	+16,3%
2021	+20,0%	+23,4%	+31,3%	+26,9%
2022	-14,1%	-0,4%	-10,4%	-19,4%
2023	+37,6%	+14,7%	+17,8%	+24,2%
2024	+18,9%	+19,5%	+15,2%	+23,3%
2025*	+11,2%	+16,2%	+7,5%	+9,8%

(2025 até agosto. Giro médio de 34% ao mês. As composições são verificáveis; agosto de 2025, por exemplo: HII, MCD, CAH, ES, MCK, MTCH, CSCO, ANET, PODD, ABNB. Séries e composições completas em [data/interim/sp500/port10_.csv](#); replicação por [scripts/sp500_port10.py](#).)

A leitura desses números pede honestidade de atribuição, e a fazemos em duas camadas. Contra o S&P 500, o excesso é de +7,1% ao ano com $t=2,60$, vitória em 58% dos meses e em 13 dos 17 anos; é o número de manchete, e é real. Mas há uma sutileza que um leitor técnico reconhecerá: uma

carteira de pesos iguais tende a superar um índice ponderado por valor simplesmente por dar mais peso a empresas menores. Para isolar o mérito da seleção, construímos a régua mais exigente possível: o próprio universo elegível em pesos iguais. Contra essa régua, a seleção por TD adiciona +3,6% ao ano ($t=1,59$), com contribuição positiva em todos os subperíodos que examinamos (de 2010 em diante, +1,8%; de 2015 em diante, +1,9%; de 2019 em diante, +2,6% ao ano), embora sem significância estatística isolada. A ausência de significância tem explicação mecânica: com apenas 10 ativos, o ruído específico de cada empresa domina a variância da carteira e dilui um efeito que o painel estima em cerca de 15 pontos-base por variação interquartil. A carteira espelho, com as 10 empresas de menor TD, rende +15,3% ao ano, 5,1 pontos abaixo do top-10, na direção prevista pela tese.

O long-short por quintis, na especificação congelada, não monetiza: os retornos líquidos anualizados ficam entre +0,3% e +4,4% conforme a construção, com o melhor Sharpe em 0,22, estatisticamente nulo, contra 0,53 do mercado no período. O diagnóstico de pernas explica o porquê: a correlação entre as pontas comprada e vendida é de apenas 0,6, e o quintil alto do sinal FinBERT carrega exposição a ações de baixa volatilidade, ou seja, um fator de risco conhecido, e não tom. Registramos as 6 construções testadas e as contabilizamos para o ajuste de múltiplas tentativas (Deflated Sharpe, Bailey e López de Prado, 2014) na entrega final.

O perfil de risco fecha a interpretação. O top-10 realiza volatilidade maior que todas as régua (20,6% contra 17,3% a 17,4%) e Sharpe semelhante ao do universo (1,01 contra 0,99). O retorno adicional, portanto, remunera risco adicional: trata-se de um prêmio de compensação por carregar as empresas cuja diretoria diverge, e não de uma anomalia gratuita, em linha com a associação descritiva entre TD e volatilidade documentada na Seção 5.4. Para a mesa, as aplicações que a evidência sustenta são quatro: tilt direcional sobre um portfólio core; condicionamento de exposição em torno de anúncios, já que o score existe minutos após cada call; posicionamento de volatilidade no próximo anúncio das empresas de divergência alta, apoiado na previsão de surpresa de lucro; e insumo em arcabouço multifator, cuja engenharia é o objeto da entrega final.

7. Riscos e limitações

1. Os papéis de orador foram reconstruídos por classificador próprio, com cerca de 90% de acerto validado; as bases comerciais curadas usadas na literatura não têm esse ruído, e parte da diferença de magnitude entre as nossas estatísticas e as publicadas pode vir daí.
2. Algumas variáveis usam proxies: a surpresa de lucro vem do Yahoo Finance em vez do consenso I/B/E/S, e dois controles da literatura (participação institucional e qualidade de accruals) não foram reconstruídos; os demais 17, sim.
3. Cerca de 3,4 mil eventos ficaram sem retorno anormal por falta de preços de empresas deslistadas em fonte gratuita, uma limitação de sobrevivência declarada.
4. O efeito no anúncio, de cerca de 0,15% por variação interquartil, não paga custos como estratégia isolada de arbitragem do evento em large caps; por isso a implementação proposta é de tilt, condicionamento e volatilidade, e não de arbitragem do anúncio.
5. Com 10 ativos, o excesso sobre o universo em pesos iguais é consistente, mas não significativo isoladamente; diversificar além de 10 nomes é o caminho natural da entrega final.

6. A definição do centro da call admite duas construções na literatura; reportamos as duas, e a escolha da agregada não foi guiada por resultado, e sim pela evidência textual da referência e pelo diagnóstico de ruído da Seção 3.

8. Conclusão e tese de investimento

O pré-relatório estabelece que a divergência de tom entre gestores é informação precificada. Confirmamos o fenômeno em universo independente, com dados públicos e código próprio; mostramos que ele sobrevive à troca completa do medidor de tom, do dicionário ao modelo neural; e o transformamos em estratégia implementável, com custos e auditoria de ausência de informação futura.

A tese de investimento, em um parágrafo: a divergência de tom entre os executivos na earnings call é informação precificada em dois tempos. No anúncio, o mercado penaliza a empresa cuja diretoria diverge, um efeito condicional negativo e estável no tempo. Nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação: a carteira das 10 maiores TD rendeu +20,4% ao ano contra +13,2% do S&P 500 em 16 anos e meio, remunerando o risco adicional que o próprio sinal identifica. O mesmo score antecipa a magnitude da surpresa do lucro seguinte, servindo de termômetro de incerteza antes de cada anúncio. A implementação recomendada combina tilt direcional, condicionamento de exposição a eventos e posicionamento de volatilidade, com a integração multifator como objeto da entrega final.

Registramos também a fronteira que não avançou. Testamos o sinal em 2.250 firmas fora do S&P 500 (2019 a 2023), com especificações congeladas por pré-registro antes de qualquer resultado (docs/PREREG_MF.md, com data registrada em git). O painel resultou inconclusivo por falta de potência estatística: coeficientes positivos, não significativos, com janela curta e cobertura de preços de 69%. No mesmo período, o efeito segue presente nas large caps ($t=-1,96$), o que aponta a causa para o universo e a qualidade dos dados, e não para a época. A fronteira permanece documentada e não é apresentada como resultado.

Até a entrega final (17/08), a agenda tem três itens: desenhar a integração multifator do score, com contagem de tentativas e Deflated Sharpe; fechar a robustez de custos e a análise de decaimento do sinal; e, havendo dados de preços de deslistadas, visitar a fronteira de small e mid caps com o pré-registro já versionado.

Uma nota de método encerra o relatório. Em amostra completa, as três hipóteses pareciam confirmadas. Foram os exercícios de robustez temporal que separaram os efeitos reais (precificação, retornos subsequentes e incerteza operacional) do artefato (risco). Esse protocolo, aplicado sem exceção e documentado no repositório, é parte central do que a equipe leva para a entrega final.

9. Uso de IA generativa no processo

O uso de GenAI neste trabalho é operacional e auditável, não declaratório. Primeiro, no núcleo do pipeline: um processo por linha de comando (claude -p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes, com cache versionado e reproprocessamento determinístico, em cerca de 4,6 horas de execução; a validação usou matriz de confusão contra 292 rótulos manuais (cerca de 90% de acerto global) e um classificador determinístico independente para comparação (99% de concordância nos casos frequentes), com prompt, custos e validação documentados em docs/GENAI_USAGE.md. Segundo, como par de engenharia e auditoria ao longo de todo o processo:

arquitetura do pipeline, código, testes, documentação e, com impacto direto no resultado, a auditoria da fórmula do centro da call, conduzida em par com o assistente (Claude), com as decisões econômicas e metodológicas sempre da equipe. Por fim, uma distinção de honestidade conceitual: o FinBERT é um modelo de linguagem do tipo encoder, parte do modelo quantitativo; é permitido pelo edital, mas o contabilizamos como NLP/ML, e não como IA generativa.

Referências

Angelo, Johnston, Singh e Wan (2025). Tone Distance: Managerial Tone Divergence and Market Reaction to Earnings. *The Financial Review*.

Bailey, D. H., e López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5).

Fama, E. F., e French, K. R. (1997). Industry Costs of Equity. *Journal of Financial Economics*, 43(2).

Huang, X., Teoh, S. H., e Zhang, Y. (2014). Tone Management. *The Accounting Review*, 89(3).

Lee, J. (2016). Can Investors Detect Managers' Lack of Spontaneity? Adherence to Predetermined Scripts during Earnings Conference Calls. *The Accounting Review*, 91(1).

Loughran, T., e McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1).

Yang, Y., Uy, M. C. S., e Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. *arXiv:2006.08097*.

Todos os números deste relatório saem de scripts versionados no repositório e foram reproduzidos em clone limpo. Nenhum número foi digitado à mão.