

CORO: Divergência de tom entre gestores como sinal quantitativo de investimento

Pré-relatório · Desafio Quant AI 2026 (Itaú Asset)

Equipe: Marcelo e Caio · Orientação: Profa. Nadia Cardoso Moreira

Repositório com código, dados e replicação completa:

<https://github.com/marceleann/Caio-e-Marcelo-e-Vinicius>

Nome do robô em definição pela equipe (alternativas em avaliação: DESAFINADO, DISSONA, OUVIDOR, CORO). O conceito é único: o robô não mede o tom médio da empresa, e sim o desalinhamento entre as vozes que a representam.

Sumário executivo

Toda earnings call é uma peça ensaiada, mas quem a executa são pessoas. Este trabalho parte de uma observação simples: quando os executivos da mesma empresa divergem no tom ao falar do mesmo trimestre, essa divergência carrega informação que a mensagem oficial não entrega. Nós transformamos essa observação em um sinal quantitativo, a Tone Distance (TD), calculada minutos após a divulgação de cada transcrição, e a testamos de ponta a ponta em 33.362 calls de 685 empresas do S&P 500 entre 2005 e 2025.

Os resultados sustentam a tese. No painel econométrico, empresas cujos gestores divergem mais sofrem retorno anormal menor no anúncio (estatística t de até 2,9 em módulo), entregam retornos maiores nos três meses seguintes ($t=+2,1$) e apresentam surpresas de lucro mais imprevisíveis no trimestre seguinte ($t=+3,58$ na previsão fora da amostra, nosso resultado preditivo mais forte). O quadro se repete em dois medidores de tom independentes, o dicionário Loughran-McDonald e o modelo neural FinBERT, o que afasta a hipótese de artefato de instrumento.

Na implementação, uma carteira que compra todo mês as 10 empresas de maior TD rendeu +20,4% ao ano, contra +13,2% do S&P 500, ao longo de 199 meses (fevereiro de 2009 a agosto de 2025), com excesso de +7,1% ao ano ($t=2,60$) e vitória em 13 dos 17 anos. O relatório também documenta o que não funcionou: a hipótese de que o sinal prevê volatilidade futura não passou nos testes de robustez e foi descartada, decisão que descrevemos em detalhe porque ela atesta o rigor do processo. Tudo o que está aqui é reproduzível a partir do repositório público com quatro comandos.

1. Contexto e problema

Quem acompanha teleconferências de resultados conhece a cena. O CEO abre com a mensagem preparada, o CFO percorre os números e, quando começa a sessão de perguntas, cada executivo responde com o tom que consegue sustentar ao vivo. O texto é coordenado; o tom, nem sempre. Coordenar a narrativa entre quatro ou cinco oradores é viável; coordenar o otimismo de cada um, frase a frase, sob pergunta de analista, é muito mais difícil.

A premissa deste trabalho é que esse descompasso é informativo. Se o CFO soa visivelmente mais cauteloso que o CEO no mesmo call, o mercado tem diante de si um indício de desacordo interno ou

de incerteza sobre o trimestre que nenhum press release admitiria. O problema de pesquisa, portanto: é possível medir essa divergência de forma sistemática, e ela tem valor econômico?

Dessa premissa saem as três hipóteses que testamos, registradas antes dos testes. Primeira: quanto maior a divergência de tom, pior a reação do mercado no anúncio. Segunda: maior divergência indicaria maior risco realizado depois do anúncio. Terceira: maior divergência antecipa resultados operacionais mais imprevisíveis nos trimestres seguintes.

O produto que materializa a resposta é o robô. Ele processa a transcrição de cada call, atribui cada fala ao seu orador, mede o tom de cada gestor e resume o desalinhamento em um único escore por empresa-trimestre, disponível minutos após a publicação da transcrição. Para uma mesa, isso significa um insumo utilizável no mesmo dia do evento: como sinal de seleção, como condicionante de exposição em torno de anúncios e como indicador antecedente de incerteza de resultados.

2. Referências

A ideia de que o tom da comunicação corporativa move preços tem lastro sólido na literatura. Loughran e McDonald (2011) construíram o dicionário de tom específico para finanças que virou padrão da área, ao mostrar que dicionários genéricos classificam mal a linguagem de negócios. Huang, Teoh e Zhang (2014) documentaram que gestores administram ativamente o tom de suas divulgações, e que o mercado reage ao componente anormal desse tom. Lee (2016) mostrou que investidores percebem quando executivos abandonam a espontaneidade e se apegam a roteiros durante earnings calls.

O passo que origina nossa medida é de Angelo, Johnston, Singh e Wan (2025), que propuseram olhar não para o tom médio da empresa, mas para a divergência de tom entre os executivos da mesma call, batizada de Tone Distance. Nosso trabalho toma essa referência como ponto de partida e a submete a um teste independente, com universo, dados e código integralmente próprios. E adiciona uma extensão deliberada: repetimos toda a análise trocando o medidor de tom, do dicionário para o FinBERT (Yang, Uy e Huang, 2020), um modelo de linguagem treinado em textos financeiros. A lógica da extensão é de validação cruzada de instrumento: se o fenômeno é real, deve aparecer nos dois medidores; se é artefato do dicionário, a troca o elimina.

3. Desenvolvimento: do texto bruto ao sinal

A matéria-prima são 33.362 transcrições de calls de empresas que integraram o S&P 500 entre 2005 e 2025 (dataset público kurry/HuggingFace, 685 empresas). Preços vêm do Yahoo Finance; fundamentos trimestrais, do SEC EDGAR, alinhados pela data de protocolo para que nenhuma informação seja usada antes de existir publicamente; a classificação setorial segue Fama e French (1997); a taxa livre de risco é a de Kenneth French.

O primeiro desafio prático é saber quem fala. Cada transcrição traz milhares de falas, e o sinal exige separar gestores de analistas e operadores. Resolvemos com um classificador em dois níveis: um modelo de linguagem via linha de comando classificou os 12.678 cabeçalhos de orador distintos da base, e regras determinísticas cobrem o restante. A classificação foi auditada contra 292 rótulos manuais, com cerca de 90% de acerto (o processo completo está na Seção 9).

Com os papéis atribuídos, o sinal se constrói em três passos. Cada gestor da call vira um ponto num plano definido pela fração de linguagem positiva e negativa de sua fala. Calcula-se o centro da call. A

Tone Distance é a distância média dos gestores a esse centro: zero quando todos soam igual, alta quando as vozes se afastam. Exigimos no mínimo dois gestores por call, e o tom de cada fala é medido duas vezes, pelo dicionário e pelo FinBERT.

Um detalhe de construção acabou virando contribuição metodológica. A definição do centro admite duas leituras: média simples dos gestores, em que cada orador pesa igual, ou tom agregado do texto completo, em que cada palavra pesa igual. A diferença não é cosmética. Em uma call da Apple de 2020, por exemplo, o profissional de relações com investidores falou apenas 283 palavras, e as únicas 6 negativas eram o aviso legal padrão sobre riscos e incertezas; na média simples, esse orador marginal respondia por um terço do sinal da call. A leitura agregada, e além dela a ponderação explícita pelo volume de fala de cada gestor, elimina essa contaminação. Como se verá na Seção 5, os resultados enfraquecem monotonicamente à medida que se dá peso a oradores marginais, o que transforma o detalhe em diagnóstico. A implementação foi verificada por reimplementação independente nas 32.387 calls elegíveis, com diferença máxima da ordem de 10^{-16} .

4. Método de teste

Os retornos anormais seguem o modelo de mercado: beta estimado por CAPM em janela de 100 pregões (mínimo de 70), separada do evento por 50 pregões, e resíduo acumulado nas janelas de 1, 2 e 5 pregões ao redor do anúncio. Calls realizadas após o fechamento (27% da amostra) são ancoradas no pregão seguinte, respeitando o horário real em que a informação chegou ao mercado.

O teste central é um painel com efeitos fixos de empresa e de ano-trimestre, erros agrupados por empresa e winsorização em 5/95, com controles de tamanho, valor, alavancagem, rentabilidade, surpresa de lucro, momentum e reversão. O efeito fixo de empresa importa para a leitura: o coeficiente não compara a Apple com a Exxon, compara a Apple de um trimestre com a própria Apple típica. O sinal mede, portanto, o desvio da empresa em relação ao seu padrão usual de alinhamento.

Para a implementação, desenhamos dois backtests independentes, ambos com custos e com a garantia, auditada nos scripts, de que nenhuma informação futura entra na seleção. O primeiro executa a tese da forma mais direta possível: ao fim de cada mês, compra em pesos iguais as 10 empresas de maior TD (call mais recente dos três meses anteriores), carrega por um mês e rebalanceia, pagando 10 pontos-base por lado sobre o giro. O segundo é um long-short por quintis em formato calendar-time, com especificação congelada antes da execução: entrada no pregão seguinte à call, manutenção de 63 pregões, ranking contra os 90 dias anteriores, custos de 5 pontos-base por perna, amostra 2006 a 2025.

Todos os números deste relatório saem de scripts versionados no repositório público. Um avaliador reproduz as regressões e os backtests com quatro comandos, sem reprocessar transcrições; o procedimento foi testado em clone limpo, com números idênticos.

5. Resultados econométricos

Antes das regressões, validamos a base. A distribuição da nossa TD (média 0,0086, mediana 0,0080, desvio 0,0047) é aderente à da referência (0,0079, 0,0074, 0,0048), e os controles reconstruídos batem com os publicados: alavancagem 0,24 contra 0,235, alíquota efetiva mediana 0,22 contra 0,21, suavização de lucros 1,6 contra 1,4. Partimos, portanto, de uma base comparável.

A primeira hipótese se confirma na amostra completa. A tabela reporta as estatísticas t do coeficiente da TD sobre o retorno anormal do anúncio, nas três janelas de evento, para as três construções do sinal e os dois medidores (amostra de 2009 em diante, cerca de 23 mil eventos e 540 empresas):

construção do sinal	LM (dicionário)	FinBERT (neural)
centro = média simples	-0,7 / -0,6 / -0,3	+0,1 / -0,2 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,9 / -2,7 / -2,3	-2,4 / -2,4 / -2,5

(t nas janelas de 1, 2 e 5 pregões. Em termos econômicos, uma variação interquartil de TD corresponde a algo entre 0,11% e 0,16% a menos de retorno anormal no anúncio.)

Três leituras. A hipótese central replica quando o sinal respeita o volume de fala de cada gestor. A progressão entre as linhas é monotônica: quanto mais peso ao ruído dos oradores marginais, mais fraco o sinal, exatamente o diagnóstico da Seção 3. E os dois medidores, que concordam entre si em apenas 38%, contam a mesma história, o que afasta artefato de instrumento.

O efeito não termina no anúncio. No painel mensal, o retorno dos três meses seguintes à call cresce com a TD (t=+2,1 no dicionário, +1,8 no FinBERT), controlando por valor, momentum, tamanho e reversão. O quadro combinado é economicamente coerente: o mercado penaliza a empresa divergente no ato e cobra um prêmio para carregá-la nos meses seguintes.

A terceira hipótese entrega o resultado preditivo mais forte do projeto. A magnitude da surpresa de lucro do trimestre seguinte cresce com a TD (t=+2,2 no painel), e no exercício de previsão fora da amostra, em que o modelo é treinado apenas com o passado e usado para prever eventos futuros, a relação alcança t=+3,58, com acerto direcional em 71% dos trimestres. Em outras palavras: a divergência de hoje avisa que o próximo balanço vem com surpresa grande, para qualquer lado.

A segunda hipótese, a de risco, não sobreviveu, e o caminho até essa conclusão merece registro. Na amostra completa existe associação entre TD e volatilidade futura (t=+2,5 no dicionário). A investigação mostrou, porém, que janelas de volatilidade que começam no dia seguinte ao anúncio ainda contêm a reação ao próprio anúncio, e empresas de TD alta reagem mais (que é justamente a primeira hipótese). Medida a partir do segundo dia, fora desse eco, a associação perde significância (t=+1,3). Nos testes de robustez, nenhuma das 16 especificações predefinidas mostrou poder de previsão. A conclusão honesta: a TD não informa sobre risco futuro nada que a volatilidade passada já não diga, e o canal foi descartado como sinal. Permanece verdadeiro, como descrição, que empresas de TD alta são em média mais voláteis, e esse fato retorna na interpretação do backtest.

Fechamos a seção com a robustez temporal, apresentada sem tecnicismo. Reestimamos tudo usando apenas os dados disponíveis até cada data de corte e conferimos no período posterior, além da previsão por evento fora da amostra. O coeficiente da primeira hipótese tem o mesmo sinal negativo em todos os cortes analisados, e a previsão fora da amostra confirma (t=-2,12, com resultado negativo em cada um dos anos de 2019 a 2025); a camada de retornos subsequentes mantém coeficiente positivo em todos os cortes; a terceira hipótese sustenta o t=+3,58 já citado. Nos primeiros anos, com menos dados acumulados, os intervalos de confiança são mais largos, como se espera de um efeito estável estimado com precisão crescente. A exceção é a hipótese de risco, reprovada nesses mesmos exercícios (t=+0,27), o que motivou o descarte. O mesmo protocolo que valida duas hipóteses reprovava a terceira; o critério não é complacente.

6. Backtest

A implementação principal executa a tese da forma que um gestor reconheceria: carteira comprada, regra fixa, rebalanceamento mensal. Os números de 199 meses (fevereiro de 2009 a agosto de 2025):

	Top-10 TD bruto	Top-10 TD líquido	Bottom-10 TD	Universe elegível EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

ano	top-10 TD	bottom-10	universe EW	S&P 500
2009	+113,1%	+44,6%	+61,3%	+35,0%
2010	+19,2%	+10,1%	+23,1%	+12,8%
2011	+4,8%	+8,6%	+0,5%	-0,0%
2012	+39,3%	+24,6%	+20,2%	+13,4%
2013	+30,5%	+53,1%	+37,8%	+29,6%
2014	+10,3%	+5,8%	+15,6%	+11,4%
2015	+5,9%	+6,8%	-1,5%	-0,7%
2016	+6,2%	+15,5%	+17,6%	+9,5%
2017	+18,2%	+12,8%	+21,6%	+19,4%
2018	+0,4%	-14,5%	-7,2%	-6,2%
2019	+44,5%	+27,1%	+31,5%	+28,9%
2020	+11,8%	+2,7%	+15,8%	+16,3%
2021	+20,0%	+23,4%	+31,3%	+26,9%
2022	-14,1%	-0,4%	-10,4%	-19,4%
2023	+37,6%	+14,7%	+17,8%	+24,2%
2024	+18,9%	+19,5%	+15,2%	+23,3%
2025*	+11,2%	+16,2%	+7,5%	+9,8%

(2025 até agosto. Giro médio de 34% ao mês. As composições são verificáveis; agosto de 2025, por exemplo: HII, MCD, CAH, ES, MCK, MTCH, CSCO, ANET, PODD, ABNB. Séries e composições completas em [data/interim/sp500/port10_.csv](#); replicação por [scripts/sp500_port10.py](#).)

A leitura desses números pede honestidade de atribuição, e a fazemos em duas camadas. Contra o S&P 500, o excesso é de +7,1% ao ano com $t=2,60$, vitória em 58% dos meses e em 13 dos 17 anos; é o número de manchete, e é real. Mas uma carteira de pesos iguais não deve ser comparada apenas a um índice ponderado por valor, e por isso construímos a régua mais exigente: o próprio universo elegível em pesos iguais. Contra ela, a seleção por TD adiciona +3,6% ao ano ($t=1,59$), positiva em todos os subperíodos que examinamos (de 2010 em diante, +1,8%; de 2015 em diante, +1,9%; de 2019 em diante, +2,6% ao ano), embora sem significância isolada, o que é a consequência esperada de concentrar em 10 ativos, onde o ruído específico de cada nome domina. A carteira espelho, com

as 10 empresas de menor TD, rende +15,3% ao ano, 5,1 pontos abaixo do top-10, na direção prevista pela tese.

O long-short por quintis, na especificação congelada, não monetiza: os retornos líquidos anualizados ficam entre +0,3% e +4,4% conforme a construção, com o melhor Sharpe em 0,22, estatisticamente nulo, contra 0,53 do mercado no período. O diagnóstico de pernas explica o porquê: a correlação entre as pontas é de apenas 0,6, e o quintil alto do sinal FinBERT carrega exposição a ações de baixa volatilidade, um fator de risco, não tom. Registramos as 6 construções testadas e as contabilizamos para o ajuste de múltiplas tentativas (Deflated Sharpe, Bailey e López de Prado, 2014) na entrega final.

O perfil de risco fecha a interpretação. O top-10 realiza volatilidade maior que todas as régua (20,6% contra 17,3% a 17,4%) e Sharpe semelhante ao do universo (1,01 contra 0,99). O retorno adicional, portanto, remunera risco adicional: é prêmio de compensação por carregar as empresas cuja diretoria diverge, não anomalia gratuita, e isso é coerente com a associação descritiva entre TD e volatilidade da Seção 5. Para a mesa, as aplicações que a evidência sustenta são quatro: tilt direcional sobre um portfólio core; condicionamento de exposição em torno de anúncios, já que o score existe minutos após cada call; posicionamento de volatilidade no próximo anúncio das empresas de divergência alta, apoiado na previsão de surpresa de lucro; e insumo em arcabouço multifator, cuja engenharia é o objeto da entrega final.

7. Riscos e limitações

1. Os papéis de orador foram reconstruídos por classificador próprio, com cerca de 90% de acerto validado; as bases comerciais curadas da literatura não têm esse ruído, e parte da diferença de magnitude entre nossas estatísticas e as publicadas pode vir daí.
2. Algumas variáveis usam proxies: surpresa de lucro via Yahoo Finance em vez de I/B/E/S, e dois controles da literatura (participação institucional e qualidade de accruals) não foram reconstruídos; os demais 17, sim.
3. Cerca de 3,4 mil eventos ficaram sem retorno anormal por falta de preços de empresas deslistadas em fonte gratuita, uma limitação de sobrevivência declarada.
4. O efeito no anúncio, de cerca de 0,15% por variação interquartil, não paga custos como estratégia isolada de arbitragem do evento em large caps; por isso a implementação proposta é de tilt, condicionamento e volatilidade, e não de arbitragem do anúncio.
5. Com 10 ativos, o excesso sobre o universo em pesos iguais é consistente mas não significativo isoladamente; diversificar além de 10 nomes é o caminho natural da entrega final.
6. A definição do centro da call admite duas construções na literatura; reportamos as duas, e a escolha da agregada não foi guiada por resultado, e sim pela evidência textual da referência e pelo diagnóstico de ruído da Seção 3.

8. Conclusão e tese de investimento

O pré-relatório estabelece que a divergência de tom entre gestores é informação precificada. Confirmamos o fenômeno em universo independente, com dados públicos e código próprio; mostramos que ele sobrevive à troca completa do medidor de tom, do dicionário ao modelo neural;

e o transformamos em estratégia implementável, com custos e auditoria de ausência de informação futura.

A tese de investimento, em um parágrafo: a divergência de tom entre os executivos na earnings call é informação precificada em dois tempos. No anúncio, o mercado penaliza a empresa cuja diretoria diverge, um efeito condicional negativo e estável no tempo. Nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação: a carteira das 10 maiores TD rendeu +20,4% ao ano contra +13,2% do S&P 500 em 16 anos e meio, remunerando o risco adicional que o próprio sinal identifica. O mesmo escore antecipa a magnitude da surpresa do lucro seguinte, servindo de termômetro de incerteza antes de cada anúncio. A implementação recomendada combina tilt direcional, condicionamento de exposição a eventos e posicionamento de volatilidade, com a integração multifator como objeto da entrega final.

Registramos também a fronteira que não avançou. Testamos o sinal em 2.250 firmas fora do S&P 500 (2019 a 2023), com especificações congeladas por pré-registro antes de qualquer resultado (docs/PREREG_MF.md, com data registrada em git). O painel resultou inconclusivo por falta de potência: coeficientes positivos, não significativos, com janela curta e cobertura de preços de 69%. No mesmo período, o efeito segue presente nas large caps ($t=-1,96$), o que aponta a causa para o universo e a qualidade dos dados, não para a época. A fronteira permanece documentada e não é apresentada como resultado.

Até a entrega final (17/08), a agenda tem três itens: desenhar a integração multifator do escore, com contagem de tentativas e Deflated Sharpe; fechar a robustez de custos e a análise de decaimento do sinal; e, havendo dados de preços de deslistadas, visitar a fronteira de small e mid caps com o pré-registro já versionado.

Uma nota de método encerra. Em amostra completa, as três hipóteses pareciam confirmadas. Foram os exercícios de robustez temporal que separaram os efeitos reais (precificação, retornos subsequentes e incerteza operacional) do artefato (risco). Esse protocolo, aplicado sem exceção e documentado no repositório, é parte central do que a equipe leva para a entrega final.

9. Uso de IA generativa no processo

O uso de GenAI neste trabalho é operacional e auditável, não declaratório. Primeiro, no núcleo do pipeline: um processo por linha de comando (claude -p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes, com cache versionado e reproprocessamento determinístico, em cerca de 4,6 horas de execução; a validação usou matriz de confusão contra 292 rótulos manuais (cerca de 90% de acerto global) e um classificador determinístico independente para comparação (99% de concordância nos casos frequentes), com prompt, custos e validação documentados em docs/GENAI_USAGE.md. Segundo, como par de engenharia e auditoria ao longo de todo o processo: arquitetura do pipeline, código, testes, documentação e, com impacto direto no resultado, a auditoria da fórmula do centro da call, conduzida em par com o assistente (Claude), com as decisões econômicas e metodológicas sempre da equipe. Por fim, uma distinção de honestidade conceitual: o FinBERT é um modelo de linguagem do tipo encoder, parte do modelo quantitativo; é permitido pelo edital, mas o contabilizamos como NLP/ML, não como IA generativa.

Referências

- Angelo, Johnston, Singh e Wan (2025). Tone Distance: Managerial Tone Divergence and Market Reaction to Earnings. *The Financial Review*.
- Bailey, D. H., e López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5).
- Fama, E. F., e French, K. R. (1997). Industry Costs of Equity. *Journal of Financial Economics*, 43(2).
- Huang, X., Teoh, S. H., e Zhang, Y. (2014). Tone Management. *The Accounting Review*, 89(3).
- Lee, J. (2016). Can Investors Detect Managers' Lack of Spontaneity? Adherence to Predetermined Scripts during Earnings Conference Calls. *The Accounting Review*, 91(1).
- Loughran, T., e McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1).
- Yang, Y., Uy, M. C. S., e Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. *arXiv:2006.08097*.

Todos os números deste relatório saem de scripts versionados no repositório e foram reproduzidos em clone limpo. Nenhum número foi digitado à mão.