

CORO: Divergência de tom entre gestores como sinal quantitativo de investimento

Pré-relatório · Desafio Quant AI 2026 (Itaú Asset)

Equipe: Marcelo e Caio · Orientação: Profa. Nadia Cardoso Moreira

Repositório com código, dados e replicação completa:

<https://github.com/marceleann/Caio-e-Marcelo-e-Vinicius>

Nome do robô em definição pela equipe (alternativas em avaliação: DESAFINADO, DISSONA, OUVIDOR, CORO). O conceito é único: o robô não mede o tom médio da empresa, e sim o desalinhamento entre as vozes que a representam.

Resumo

Este trabalho constrói e valida um sinal quantitativo extraído das teleconferências de resultados: a divergência de tom entre os executivos da mesma empresa (Tone Distance, TD). Processamos 33.362 transcrições de calls de 685 empresas do S&P 500 (2005 a 2025) com um pipeline próprio que combina classificação de papéis por LLM e dois medidores independentes de tom (dicionário Loughran-McDonald e o modelo neural FinBERT). Os testes em painel confirmam a hipótese central: maior divergência de tom está associada a retorno anormal menor no anúncio (t até $-2,9$), a retornos maiores nos meses seguintes ($t=+2,1$) e a maior imprevisibilidade do lucro do trimestre seguinte ($t=+3,58$ na previsão fora da amostra). A estratégia derivada do sinal, uma carteira mensal com as 10 empresas de maior TD, rendeu $+20,4\%$ ao ano contra $+13,2\%$ do S&P 500 em 199 meses, com excesso estatisticamente significativo ($t=2,60$). A hipótese de previsão de risco não sobreviveu aos testes de robustez e foi descartada, decisão que documenta o rigor do processo de validação. Todos os resultados são reproduzíveis a partir do repositório público com 4 comandos.

Palavras-chave: análise de texto; earnings calls; tom gerencial; retornos anormais; FinBERT; estratégia quantitativa.

1. Introdução

Em uma teleconferência de resultados, a empresa apresenta uma mensagem coordenada, mas quem fala são pessoas: CEO, CFO e diretores respondem a perguntas ao vivo, sem controle total sobre o tom que empregam. Quando os tons desses executivos divergem entre si, a divergência pode revelar informação que a comunicação oficial não captura: desacordo interno, incerteza sobre o trimestre, narrativas que não fecham. A hipótese central deste trabalho é que essa divergência é mensurável e é precificada pelo mercado.

Identidade do robô. O robô processa a transcrição de cada teleconferência e converte o grau de desalinhamento entre os executivos em um número: a Tone Distance (TD), definida como a dispersão do tom entre os gestores que falam na mesma call. A saída é objetiva e operacional: um score por empresa-trimestre, disponível minutos após a divulgação da transcrição, utilizável como sinal de seleção de ativos, como condicionante de exposição a eventos e como indicador antecedente de

incerteza de resultados. O nome em avaliação pela equipe (DESAFINADO) resume o conceito: o robô não mede o que a empresa diz, mede o quanto as vozes dela desafinam ao dizer.

Objetivo e hipóteses. Testamos três hipóteses sobre a TD, formuladas a partir da literatura e registradas antes dos testes: (H1) maior divergência de tom implica retorno anormal menor no anúncio; (H2) maior divergência implica maior risco realizado após o anúncio; (H3) maior divergência antecipa piora ou imprevisibilidade dos resultados operacionais seguintes. Sobre as hipóteses validadas, construímos e testamos uma estratégia de investimento com custos de transação.

Principais resultados. H1 confirma-se na amostra completa, com o mesmo quadro em dois medidores de tom independentes, o que descarta artefato de instrumento. O sinal também está associado a retornos maiores nos três meses seguintes à call, e H3 produz o resultado preditivo mais forte do projeto: a divergência de hoje antecipa a magnitude da surpresa do lucro do próximo trimestre. A carteira mensal com as 10 empresas de maior TD rendeu +20,4% ao ano contra +13,2% do S&P 500 em 16 anos e meio. H2 não passou nos testes de robustez e foi descartada como sinal.

Contribuições. Três: (i) metodológica, o diagnóstico de como medir a divergência de tom (a ponderação pelo volume de fala de cada gestor separa sinal de ruído, e a troca do dicionário pelo FinBERT confirma o achado); (ii) empírica, a validação independente do fenômeno em universo, dados e código próprios, com a honestidade de descartar a hipótese que não validou; (iii) de infraestrutura, um pipeline integralmente replicável com dados públicos.

Organização. A Seção 2 apresenta a fundamentação teórica e as hipóteses. A Seção 3 descreve dados e metodologia. A Seção 4 reporta os resultados econométricos e a Seção 5 os resultados do backtest. A Seção 6 discute limitações, a Seção 7 conclui e a Seção 8 documenta o uso de IA generativa no processo, critério específico do edital.

2. Fundamentação teórica e hipóteses

A literatura de análise textual em finanças mostra que o tom da comunicação corporativa contém informação relevante para preços, e que o mercado extrai mais informação justamente dos componentes que os gestores têm menos capacidade de administrar. Huang, Teoh e Zhang (2014) documentam o gerenciamento de tom em divulgações de resultados; Lee (2016) mostra que o mercado reage à falta de espontaneidade dos gestores em earnings calls; Loughran e McDonald (2011) estabelecem o dicionário de tom específico para finanças que se tornou padrão na área.

Dentro dessa agenda, Angelo, Johnston, Singh e Wan (2025) propõem uma medida nova: em vez de medir o tom médio da empresa, medir a divergência de tom entre os executivos que falam na mesma call. O argumento econômico é que a mensagem oficial é ensaiada, mas a coordenação fina do tom entre vários oradores em tempo real é custosa, especialmente na sessão de perguntas e respostas. A divergência funciona, assim, como um vazamento de informação privada sobre desacordo e incerteza internos.

Nosso trabalho parte dessa referência e a submete a um teste independente, com universo, dados e código integralmente próprios, e com uma extensão deliberada: a substituição completa do medidor de tom por um modelo de linguagem neural treinado para finanças (FinBERT; Yang, Uy e Huang, 2020). Se o fenômeno é real, ele deve aparecer nos dois medidores; se é artefato do dicionário, a troca de instrumento o elimina. As hipóteses testadas são:

- **H1 (precificação):** maior Tone Distance está associada a retorno

anormal menor na janela do anúncio.

- **H2 (risco):** maior Tone Distance está associada a maior volatilidade realizada após o anúncio.
- **H3 (operacional):** maior Tone Distance antecipa piora ou maior imprevisibilidade dos resultados operacionais seguintes.

3. Metodologia

3.1 Dados e amostra

A base de transcrições é o dataset público kurry (HuggingFace), com 33.362 earnings calls de 685 empresas que integraram o S&P 500 entre 2005 e 2025. Preços e retornos vêm do Yahoo Finance; fundamentos trimestrais, do SEC EDGAR (XBRL), alinhados pela data de protocolo para evitar viés de antecipação; a classificação setorial segue Fama e French (1997), aplicada via código SIC; a taxa livre de risco é a da base de Kenneth French.

Cada fala da transcrição é atribuída a um papel (gestor, analista ou operador) por um classificador em dois níveis: um LLM via linha de comando processou os 12.678 cabeçalhos de orador distintos e regras determinísticas cobrem os casos restantes. A classificação foi validada com matriz de confusão contra 292 rótulos manuais, com cerca de 90% de acerto global (detalhes na Seção 8).

3.2 Construção da medida de divergência de tom

Para cada call, cada gestor é representado como um ponto no plano definido pela fração de sentenças (ou palavras) positivas e negativas de sua fala. A Tone Distance da call é a distância euclidiana média entre os gestores e o centro da call, exigindo no mínimo dois gestores. O tom é medido de duas formas independentes: pela contagem de palavras positivas e negativas do dicionário Loughran-McDonald e pela classificação de cada sentença pelo FinBERT.

A definição do centro da call admite duas construções, e o diagnóstico da diferença entre elas é uma contribuição deste trabalho. Na construção por média simples, cada gestor pesa igual, e um orador de participação marginal desloca o centro. Um caso concreto ilustra o problema: em uma call da Apple em 2020, um profissional de relações com investidores falou 283 palavras, das quais as únicas 6 classificadas como negativas pertenciam ao aviso legal padrão, e esse único ponto respondia por um terço do peso do sinal. Na construção agregada, o centro é o tom do texto completo da call, e cada palavra pesa igual; a ponderação adicional pelo volume de fala de cada gestor leva a ideia ao sinal individual. As três construções são reportadas na Seção 4, e a progressão dos resultados entre elas diagnostica exatamente quanto custa dar peso a oradores marginais.

A implementação foi verificada por reimplementação independente nas 32.387 calls elegíveis, com diferença máxima de 8×10^{-17} , e por exemplo auditável manualmente.

3.3 Retornos anormais e variáveis de controle

Os retornos anormais (CAR) seguem o modelo de mercado CAPM: beta estimado em janela de 100 pregões (mínimo de 70), separada do evento por um intervalo de 50 pregões, e acumulação do resíduo nas janelas $[-1,+1]$, $[-1,+2]$ e $[-1,+5]$ centradas no dia do anúncio. Calls realizadas após o fechamento do pregão (27% da amostra) são ancoradas no pregão seguinte. Os controles

reconstruídos incluem tamanho, book-to-market, alavancagem, rentabilidade, surpresa de lucro, momentum, reversão e efeitos fixos de empresa e de ano-trimestre, com erros-padrão agrupados por empresa e winsorização em 5/95.

3.4 Especificação econométrica

O teste central regride o resultado de interesse de cada hipótese (CAR do anúncio para H1; volatilidade realizada pós-anúncio para H2; magnitude da surpresa de lucro seguinte para H3; retorno dos três meses seguintes para a análise de retornos subsequentes) contra a TD e os controles, em painel com efeitos fixos de empresa e de tempo. O efeito fixo de empresa é essencial para a interpretação: o coeficiente mede o efeito de a MESMA empresa divergir mais do que o seu próprio padrão, e não diferenças permanentes entre empresas.

3.5 Desenho do backtest

Duas implementações independentes, ambas com custos e sem informação futura na seleção:

1. **Carteira executada (implementação principal).** No fechamento de cada mês, compram-se em pesos iguais as 10 empresas de maior TD, usando a call mais recente dos 3 meses anteriores; a posição é mantida pelo mês seguinte e rebalanceada. Custos de 10 pontos-base por lado sobre o turnover realizado. O script audita, mês a mês, que nenhuma call utilizada é posterior ao início do mês investido.
2. **Long-short por quintis (especificação congelada antes da execução).** Carteira com tranches sobrepostas, entrada no fechamento do pregão seguinte à call, manutenção de 63 pregões, ranking do sinal contra os 90 dias anteriores, quintis extremos com direção fixada a priori, custos de 5 pontos-base por perna, amostra completa 2006 a 2025.

3.6 Replicabilidade

O repositório público contém código, documentação e dados derivados versionados. Qualquer avaliador reproduz todas as regressões e backtests com 4 comandos, sem reprocessamento das transcrições. O procedimento foi verificado pela equipe em clone limpo, com números idênticos.

4. Resultados econômétricos

Esta seção reporta os testes de hipótese. Os retornos da estratégia estão na Seção 5.

4.1 Validação da base

Antes de qualquer regressão, verificamos que a base reconstruída é aderente à literatura: a distribuição da nossa TD (média 0,0086, mediana 0,0080, desvio 0,0047) é próxima da reportada na referência (0,0079, 0,0074, 0,0048), e os controles batem com os valores publicados (alavancagem 0,24 contra 0,235; alíquota efetiva mediana 0,22 contra 0,21; suavização de lucros 1,6 contra 1,4).

4.2 H1, precificação no anúncio: confirmada

A tabela reporta as estatísticas t do coeficiente da TD sobre o CAR do anúncio, nas três janelas de evento, para as três construções do sinal e os dois medidores de tom (amostra 2009 em diante, cerca de 23 mil eventos e 540 empresas):

construção do sinal	LM (dicionário)	FinBERT (neural)
---------------------	-----------------	------------------

centro = média simples	-0,7 / -0,6 / -0,3	+0,1 / -0,2 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,9 / -2,7 / -2,3	-2,4 / -2,4 / -2,5

(t nas janelas [-1,+1] / [-1,+2] / [-1,+5]. Efeito econômico: uma variação interquartil de TD corresponde a -0,11% a -0,16% de CAR.)

Três conclusões. Primeira: H1 confirma-se na amostra completa quando o sinal respeita o volume de fala de cada gestor. Segunda: a progressão entre as linhas é monotônica; quanto mais peso ao ruído de oradores marginais, mais fraco o sinal, o que explica por que a construção por média simples falha. Terceira: os dois medidores de tom, cuja correlação entre si é de apenas 38%, produzem o mesmo quadro; o resultado não é artefato do instrumento.

4.3 Retornos subsequentes: confirmados

No painel mensal (retorno dos três meses após a call, efeitos fixos de empresa e mês, controles de valor, momentum, tamanho e reversão), o coeficiente da TD é positivo e significativo nos dois medidores (t=+2,1 no LM; t=+1,8 no FinBERT). Combinado à H1, o quadro é economicamente coerente: o mercado penaliza a empresa no anúncio e exige retorno maior para carregá-la nos meses seguintes, um prêmio de compensação pelo risco revelado.

4.4 H3, incerteza operacional: confirmada

A magnitude da surpresa de lucro do trimestre seguinte aumenta com a TD (t=+2,2 no painel completo). No exercício de previsão fora da amostra (Seção 4.6), este é o resultado preditivo mais forte do projeto: t=+3,58, com acerto direcional em 71% dos trimestres. A divergência de tom de hoje antecipa a imprevisibilidade do resultado do próximo trimestre.

4.5 H2, risco: descartada como sinal

Na amostra completa existe associação entre TD e volatilidade futura (t=+2,5 no medidor LM; ausente no FinBERT). A investigação econométrica localizou a origem: janelas de volatilidade que começam no dia seguinte ao anúncio ainda contêm a própria reação ao anúncio, e empresas de TD alta têm reação maior (que é exatamente a H1). Medida a partir do segundo dia, fora desse eco, a associação perde significância (t=+1,3). Nos testes de robustez, nenhuma das 16 especificações pré-definidas (com e sem o eco, dois horizontes, nível e log, duas construções do sinal) mostrou poder preditivo. A conclusão é que a TD não adiciona informação de risco além da que a volatilidade passada e os controles já contêm, e o canal foi descartado como sinal. A associação permanece verdadeira como descrição (empresas de TD alta são, em média, mais voláteis) e é incorporada à interpretação econômica do prêmio na Seção 5.3.

4.6 Robustez e estabilidade temporal

Além do painel em amostra completa, submetemos cada hipótese a dois exercícios de robustez: (i) reestimação usando apenas os dados disponíveis até cada data de corte, com verificação no período posterior; e (ii) previsão por evento fora da amostra, em que o modelo condicional é treinado só com o passado e usado para prever eventos futuros.

Os resultados sustentam as conclusões das seções anteriores. O coeficiente de H1 tem o mesmo sinal negativo em todos os cortes analisados, e a previsão fora da amostra confirma o efeito (t=-2,12, com

spread negativo em cada um dos anos de 2019 a 2025). A camada de retornos subsequentes mantém coeficiente positivo em todos os cortes. H3 entrega $t=+3,58$ fora da amostra. Nos períodos iniciais, com menos dados acumulados, os intervalos de confiança são naturalmente mais largos; a significância plena aparece na amostra completa, que é o comportamento esperado de um efeito estável estimado com precisão crescente. A exceção é a H2, que reprova nesses mesmos exercícios ($t=+0,27$ fora da amostra), o que motivou seu descarte. O fato de o mesmo protocolo validar duas hipóteses e reprovar uma terceira evidencia que o critério não é complacente.

5. Resultados do backtest

5.1 Carteira das 10 maiores TD

Resultados da implementação principal em 199 meses (fevereiro de 2009 a agosto de 2025):

	Top-10 TD bruto	Top-10 TD líquido	Bottom-10 TD	Universo elegível EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

ano	top-10 TD	bottom-10	universo EW	S&P 500
2009	+113,1%	+44,6%	+61,3%	+35,0%
2010	+19,2%	+10,1%	+23,1%	+12,8%
2011	+4,8%	+8,6%	+0,5%	-0,0%
2012	+39,3%	+24,6%	+20,2%	+13,4%
2013	+30,5%	+53,1%	+37,8%	+29,6%
2014	+10,3%	+5,8%	+15,6%	+11,4%
2015	+5,9%	+6,8%	-1,5%	-0,7%
2016	+6,2%	+15,5%	+17,6%	+9,5%
2017	+18,2%	+12,8%	+21,6%	+19,4%
2018	+0,4%	-14,5%	-7,2%	-6,2%
2019	+44,5%	+27,1%	+31,5%	+28,9%
2020	+11,8%	+2,7%	+15,8%	+16,3%
2021	+20,0%	+23,4%	+31,3%	+26,9%
2022	-14,1%	-0,4%	-10,4%	-19,4%
2023	+37,6%	+14,7%	+17,8%	+24,2%
2024	+18,9%	+19,5%	+15,2%	+23,3%
2025*	+11,2%	+16,2%	+7,5%	+9,8%

(2025 até agosto. Turnover médio de 34% ao mês. As composições são verificáveis; por exemplo, agosto de 2025: HII, MCD, CAH, ES, MCK, MTCH, CSCO, ANET, PODD, ABNB. Séries mensais e composições completas em ``data/interim/sp500/port10.csv``; replicação por `scripts/sp500_port10.py``.)

Análise. O excesso sobre o S&P 500 é de +7,1% ao ano ($t=2,60$), com vitória em 58% dos meses e em 13 dos 17 anos. Para atribuição correta, comparamos também com o universo elegível em pesos iguais, que isola o efeito da ponderação: contra essa régua, a seleção por TD adiciona +3,6% ao ano ($t=1,59$), positivo em todos os subperíodos analisados (de 2010 em diante, +1,8%; de 2015 em diante, +1,9%; de 2019 em diante, +2,6% ao ano), embora sem significância isolada, consequência esperada da concentração em 10 ativos, na qual o ruído específico de cada empresa domina. A carteira espelho (as 10 de menor TD) rende +15,3% ao ano, 5,1 pontos percentuais abaixo do top-10, na direção prevista pela tese.

5.2 Estratégia long-short por quintis

Na especificação congelada da Seção 3.5, o formato long-short por quintis não monetiza o sinal: os retornos líquidos anualizados variam de +0,3% a +4,4% conforme a construção (melhor Sharpe 0,22, estatisticamente nulo), contra Sharpe de 0,53 do mercado no período. O diagnóstico de pernas explica: a correlação entre as pontas long e short é baixa (0,6), e o quintil alto do sinal FinBERT embute exposição a ações de baixa volatilidade, um fator de risco, não tom. Reportamos as 6 construções testadas e as contabilizamos para fins de ajuste de múltiplas tentativas (Deflated Sharpe; Bailey e López de Prado, 2014) na entrega final.

5.3 Interpretação e aplicações

A leitura conjunta das duas implementações delimita o que a estratégia entrega. O prêmio da TD é real e direcional, mas de magnitude moderada (cerca de 15 pontos-base por variação interquartil no painel): em formato long-short de quintis ele não paga custos, e em carteira concentrada ele aparece com consistência em todos os subperíodos. O perfil de risco confirma a interpretação de prêmio de compensação: o top-10 realiza volatilidade maior que as demais régua (20,6% contra 17,3% a 17,4%) e Sharpe semelhante ao do universo (1,01 contra 0,99), ou seja, o retorno adicional remunera o risco adicional das empresas de maior divergência. É o mesmo padrão descritivo documentado na Seção 4.5: o diferencial de volatilidade entre o top-10 e o bottom-10, de 6,1 pontos percentuais no período 2009 a 2014, cai para 1,2 ponto no período 2015 a 2025, confirmando por método independente que o canal de risco não é um sinal explorável.

As aplicações sustentadas pela evidência: (i) tilt direcional, com a carteira de maior TD como sobreposição a um portfólio core; (ii) condicionamento de exposição a eventos, já que o score fica disponível minutos após cada call e precifica o anúncio; (iii) posicionamento de volatilidade em torno do próximo anúncio das empresas de divergência alta, sustentado pela previsão da surpresa de lucro ($t=+3,58$); (iv) insumo em arcabouço multifator, cuja engenharia é o objeto da entrega final. Não há testes pendentes: toda afirmação deste relatório tem validação executada e reportada.

Vieses tratados: período completo 2005 a 2025, sem seleção; execução no pregão seguinte com carimbo de hora da call; universo com 685 empresas históricas do índice; custos incluídos; direção e janelas fixadas antes dos testes; auditoria de ausência de informação futura embutida nos scripts.

6. Discussão e limitações

1. **Papéis de orador reconstruídos** (cerca de 90% de acerto validado): as bases comerciais curadas usadas na literatura não têm esse ruído; parte da diferença de magnitude entre nossas estatísticas e as publicadas pode vir daí.

2. **Proxies:** surpresa de lucro via Yahoo Finance (não I/B/E/S); sem participação institucional (13F) e qualidade de accruals entre os controles; os demais 17 controles foram reconstruídos de fontes primárias.
3. **Sobrevivência parcial:** cerca de 3,4 mil eventos sem CAR por falta de preços de empresas deslistadas em fonte gratuita.
4. **Magnitude do efeito no anúncio:** $-0,15\%$ por variação interquartil não paga custos como estratégia isolada de arbitragem do anúncio em large caps; por isso a implementação proposta é de tilt, condicionamento e volatilidade.
5. **Concentração da carteira:** com 10 ativos, o excesso sobre o universo em pesos iguais é consistente mas não significativo isoladamente; diversificação maior é o caminho natural na entrega final.
6. **Ambiguidade de especificação na literatura:** a definição do centro da call admite duas construções; reportamos as duas e a escolha não foi guiada por resultado, e sim pela evidência textual da referência e pelo diagnóstico de ruído da Seção 3.2.

7. Conclusão

Este pré-relatório estabelece que a divergência de tom entre gestores é informação precificada. Confirmamos o efeito em universo independente com dados públicos, mostramos que ele sobrevive à troca completa do medidor de tom (do dicionário para o modelo neural) e transformamos o sinal em uma estratégia implementável e auditável.

Tese de investimento. A divergência de tom entre os executivos na earnings call é informação precificada em dois tempos. No anúncio, o mercado penaliza a empresa cuja diretoria diverge (efeito condicional negativo e estável no tempo). Nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação: a carteira das 10 maiores TD rendeu $+20,4\%$ ao ano contra $+13,2\%$ do S&P 500 em 16 anos e meio, remunerando o risco adicional que o próprio sinal identifica. O mesmo score antecipa a magnitude da surpresa do lucro seguinte, funcionando como indicador antecedente de incerteza pré-anúncio. A implementação recomendada combina tilt direcional, condicionamento de exposição a eventos e posicionamento de volatilidade, com a integração multifator como objeto da entrega final.

Extensão para small e mid caps (teste pré-registrado). Testamos o sinal em universo de 2.250 firmas fora do S&P 500 (2019 a 2023), com hipóteses e especificações congeladas por pré-registro antes de qualquer resultado (docs/PREREG_MF.md, com registro de data em git). O painel resultou inconclusivo por falta de potência (coeficientes positivos, não significativos; janela curta; cobertura de preços de 69%). No mesmo período, o efeito segue presente nas large caps ($t=-1,96$), o que isola a causa no universo e na qualidade dos dados, não na época. A fronteira permanece documentada e não é apresentada como resultado.

Próximos passos até a entrega final (17/08): (1) desenho da integração multifator do score, com contagem de tentativas e Deflated Sharpe; (2) robustez final de custos e análise de decaimento do sinal; (3) havendo dados de preços de deslistadas, visitar a fronteira small/mid com o pré-registro já versionado.

Nota de método. Em amostra completa, as três hipóteses pareciam confirmadas. Foram os exercícios de robustez temporal que separaram os efeitos reais (H1, H3 e o prêmio de retornos subsequentes) do artefato (H2). Esse protocolo de validação, aplicado sem exceção, é parte central do que a equipe leva para a entrega final.

8. Uso de IA generativa no processo

O uso de GenAI é operacional e auditável, não declaratório:

1. **Classificação de papéis por LLM (núcleo do pipeline).** Um processo por linha de comando (claude -p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes, com cache versionado e reprocessamento determinístico (cerca de 4,6 horas de execução). Validação: matriz de confusão contra 292 rótulos manuais (cerca de 90% de acerto global) e classificador determinístico independente para comparação (99% de concordância nos casos frequentes). Prompt, custos e validação documentados em docs/GENAI_USAGE.md.
2. **Par de engenharia e auditoria (processo inteiro).** Arquitetura do pipeline, código, testes, documentação e, com impacto direto no resultado, a auditoria da fórmula do centro da call: a reimplementação independente e o teste das duas construções foram conduzidos em par com o assistente (Claude), com as decisões econômicas e metodológicas sempre da equipe.
3. **O que não contabilizamos como GenAI:** o FinBERT é um modelo de linguagem do tipo encoder (classificação), parte do modelo quantitativo; permitido pelo edital, mas contabilizado como NLP/ML, não como IA generativa.

Referências

Angelo, Johnston, Singh e Wan (2025). Tone Distance: Managerial Tone Divergence and Market Reaction to Earnings. *The Financial Review*.

Bailey, D. H., e López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5).

Fama, E. F., e French, K. R. (1997). Industry Costs of Equity. *Journal of Financial Economics*, 43(2).

Huang, X., Teoh, S. H., e Zhang, Y. (2014). Tone Management. *The Accounting Review*, 89(3).

Lee, J. (2016). Can Investors Detect Managers' Lack of Spontaneity? Adherence to Predetermined Scripts during Earnings Conference Calls. *The Accounting Review*, 91(1).

Loughran, T., e McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1).

Yang, Y., Uy, M. C. S., e Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. arXiv:2006.08097.

Todos os números deste relatório saem de scripts versionados no repositório e foram reproduzidos em clone limpo. Nenhum número foi digitado à mão.