

CORO: Divergência de tom entre gestores como sinal quantitativo de investimento

Pré-relatório · Desafio Quant AI 2026 (Itaú Asset)

Equipe: Marcelo e Caio · Orientação: Profa. Nadia Cardoso Moreira

Repositório com código, dados e replicação completa:

<https://github.com/marceleann/Caio-e-Marcelo-e-Vinicius>

Nome do robô em definição pela equipe (alternativas em avaliação: DESAFINADO, DISSONA, OUVIDOR, CORO). O conceito é único: o robô não mede o tom médio da empresa, e sim o desalinhamento entre as vozes que a representam.

Sumário executivo

Este pré-relatório apresenta a construção e a validação de um sinal quantitativo extraído das teleconferências de resultados: a divergência de tom entre os executivos de uma mesma empresa, medida pela Tone Distance (TD). A motivação parte de uma observação simples do dia a dia do mercado. Embora a mensagem de uma earnings call seja ensaiada, quem a executa são pessoas, e quando os executivos divergem no tom ao falar do mesmo trimestre, essa divergência pode carregar informação que o comunicado oficial não entrega. Nesse sentido, foram processadas 33.362 transcrições de calls de 685 empresas do S&P 500, entre 2005 e 2025, com o objetivo de verificar se essa informação é precificada.

Os resultados confirmam a tese central. Empresas cujos gestores divergem mais apresentam retorno anormal menor no dia do anúncio, retornos maiores nos três meses seguintes e surpresas de lucro mais imprevisíveis no trimestre posterior, sendo este último o resultado preditivo mais forte do estudo. Além disso, o mesmo quadro se repete em dois medidores de tom independentes, o dicionário Loughran-McDonald e o modelo neural FinBERT, o que afasta a possibilidade de o achado ser um artefato do instrumento de medida.

Na implementação, a carteira que compra mensalmente as 10 empresas de maior TD rendeu +20,4% ao ano, contra +13,2% do S&P 500, ao longo de 199 meses (fevereiro de 2009 a agosto de 2025), com ganho em 13 dos 17 anos. Por fim, o relatório também documenta o que não funcionou: a hipótese de que o sinal prevê volatilidade futura não resistiu aos testes de robustez e foi descartada, decisão que optamos por detalhar no texto justamente por evidenciar o rigor do processo de validação. Todos os resultados podem ser reproduzidos a partir do repositório público com quatro comandos.

1. Contexto e problema

Quem acompanha teleconferências de resultados conhece a cena. O CEO abre com a mensagem preparada, o CFO percorre os números e, quando começa a sessão de perguntas e respostas, cada executivo responde com o tom que consegue sustentar ao vivo. O texto é coordenado, mas o tom nem sempre acompanha, uma vez que alinhar a narrativa entre quatro ou cinco oradores é viável, enquanto alinhar o otimismo de cada um, frase a frase, sob pergunta de analista, é consideravelmente mais difícil.

Diante desse cenário, a premissa do trabalho é que esse descompasso carrega informação. Um CFO que soa visivelmente mais cauteloso que o CEO na mesma call representa um indício de desacordo interno, ou de incerteza sobre o trimestre, que dificilmente apareceria em um press release. Dessa forma, duas perguntas estruturam a pesquisa: é possível medir essa divergência de forma sistemática? E, uma vez medida, ela tem valor econômico?

Dessas perguntas derivam as três hipóteses do estudo, registradas antes de qualquer teste:

- H1 (precificação): quanto maior a divergência de tom em uma call, menor o retorno anormal da empresa na janela do anúncio.
- H2 (risco): quanto maior a divergência, maior a volatilidade realizada da ação após o anúncio.
- H3 (operacional): quanto maior a divergência, mais imprevisível o resultado do trimestre seguinte.

Para responder a essas perguntas, desenvolveu-se o robô que dá identidade ao projeto. Ele lê a transcrição de cada call, atribui cada fala ao seu orador, mede o tom de cada gestor e resume o desalinhamento em um escore por empresa-trimestre, disponível minutos após a publicação da transcrição. Na prática, isso se traduz em um insumo utilizável no mesmo dia do evento, seja como sinal de seleção de ativos, seja como condicionante de exposição em torno de anúncios, seja ainda como termômetro antecedente de incerteza de resultados.

2. Referencial teórico

A ideia de que o tom da comunicação corporativa move preços é bem estabelecida na literatura de finanças textuais. Loughran e McDonald (2011) mostraram que dicionários genéricos de sentimento leem mal a linguagem de negócios, uma vez que termos como liability são negativos no uso comum e neutros em finanças, e construíram o dicionário específico que se tornou padrão da área. Na mesma linha, Huang, Teoh e Zhang (2014) documentaram que gestores administram ativamente o tom de suas divulgações e que o mercado reage ao componente anormal desse tom. Ademais, Lee (2016) demonstrou que investidores percebem, e penalizam, executivos que abandonam a espontaneidade e se apegam a roteiros durante as earnings calls.

Nesse contexto, a medida utilizada neste trabalho vem de Angelo, Johnston, Singh e Wan (2025). Em vez da pergunta clássica sobre o tom médio da empresa, os autores investigam o quanto os executivos de uma mesma call divergem entre si, dando origem à Tone Distance. O argumento econômico é o mesmo apresentado na Seção 1: a mensagem se ensaia, mas o tom fino de cada orador não, de modo que a divergência funciona como um vazamento de informação privada.

Com base nessa referência, o presente estudo realiza um teste independente, com universo, dados e código próprios, e acrescenta uma extensão deliberada: toda a análise foi refeita trocando o medidor de tom, do dicionário para o FinBERT (Yang, Uy e Huang, 2020), um modelo de linguagem treinado em textos financeiros que classifica cada sentença pelo contexto, e não por palavras isoladas. A troca serve como contraprova do instrumento, já que um fenômeno real deve aparecer nos dois medidores, enquanto um artefato de dicionário desapareceria na passagem de um para o outro.

3. Dados e construção do sinal

A amostra é composta por 33.362 transcrições de calls de empresas que integraram o S&P 500 entre 2005 e 2025 (dataset público kurry/HuggingFace, 685 empresas, incluindo as que saíram do índice, o que reduz o viés de sobrevivência). Os preços vêm do Yahoo Finance, enquanto os fundamentos trimestrais vêm do SEC EDGAR, alinhados pela data de protocolo, de modo que nenhuma informação é utilizada antes de existir publicamente. A classificação setorial segue Fama e French (1997), e a taxa livre de risco é a da base de Kenneth French.

O primeiro obstáculo prático foi identificar quem fala. Uma transcrição contém milhares de falas, e o sinal exige separar gestores de analistas e operadores. Para isso, montou-se um classificador em dois níveis: um modelo de linguagem, acionado via linha de comando, classificou os 12.678 cabeçalhos de orador distintos da base, e regras determinísticas cobrem o restante. O resultado foi auditado contra 292 rótulos feitos à mão, alcançando cerca de 90% de acerto (o processo completo está descrito na Seção 9).

Com os papéis atribuídos, o cálculo do sinal ocorre em três passos. Primeiramente, cada gestor i da call é representado por um vetor $g(i) = (p(i), n(i))$, em que p e n são as frações de linguagem positiva e negativa da sua fala. Em seguida, calcula-se o centro c da call. Por fim, a Tone Distance é obtida como a média das distâncias euclidianas dos gestores a esse centro: $TD = (1/N) \sum \|g(i) - c\|$. A medida vale zero quando todos soam igual e cresce conforme as vozes se afastam. Exige-se um mínimo de dois gestores por call, e cada fala é medida duas vezes, uma pelo dicionário e outra pelo FinBERT.

Vale destacar que um detalhe dessa construção acabou rendendo a principal contribuição metodológica do trabalho: a definição do centro c . Existem duas leituras possíveis. Na média simples, c é a média dos vetores dos gestores, e cada orador pesa igual, tenha falado uma hora ou trinta segundos. No tom agregado, c é o tom do texto completo da call, e cada palavra pesa igual. A diferença parece cosmética, mas não é, e um caso concreto ilustra o problema: em uma call da Apple de 2020, o profissional de relações com investidores falou apenas 283 palavras, das quais as únicas 6 classificadas como negativas pertenciam ao aviso legal padrão sobre riscos e incertezas, e, ainda assim, na média simples esse orador marginal respondia por um terço do sinal da call inteira. O tom agregado corrige essa contaminação, e a ponderação explícita de cada gestor pelo volume de fala leva a correção ao limite. Como será demonstrado na Seção 5, os resultados enfraquecem gradualmente conforme se devolve peso aos oradores marginais, o que transforma o detalhe em diagnóstico. A implementação foi verificada por reimplementação independente nas 32.387 calls elegíveis, com diferença máxima da ordem de 10^{-16} , além de um exemplo auditável manualmente.

4. Método de teste

Dois conceitos sustentam a parte empírica e merecem definição antes dos números. O primeiro é o retorno anormal acumulado (CAR), que corresponde à diferença entre o retorno observado da ação e o retorno que o CAPM previa dado o movimento do mercado, acumulada ao longo da janela do evento. O beta de cada evento é estimado em uma janela de 100 pregões (mínimo de 70), separada do evento por 50 pregões para não contaminar a estimativa, e o resíduo é acumulado nas janelas de 1, 2 e 5 pregões ao redor do anúncio. Além disso, as calls realizadas após o fechamento do mercado (27% da amostra) são ancoradas no pregão seguinte, respeitando o momento em que a informação de fato chegou ao investidor.

O segundo conceito é o painel com efeitos fixos, que constitui a espinha dorsal dos testes. A regressão atribui um intercepto próprio a cada empresa e a cada trimestre, e controla por tamanho, valor, alavancagem, rentabilidade, surpresa de lucro, momentum e reversão, com erros-padrão agrupados por empresa e winsorização em 5/95, procedimento que trunca os 5% mais extremos de cada variável para conter o efeito de outliers. O efeito fixo de empresa muda a natureza da comparação, uma vez que o coeficiente não compara a Apple com a Exxon, e sim a Apple de um trimestre com a própria Apple típica. O que se mede, portanto, é o efeito de a empresa divergir mais do que o seu padrão usual.

Para a leitura dos resultados, reporta-se sempre a estatística t de cada coeficiente, que expressa quantos erros-padrão o efeito estimado dista de zero, sendo que, pela convenção usual, valores acima de 2 em módulo indicam significância ao nível de 5%.

Na etapa de implementação, foram desenhados dois backtests independentes, ambos com custos de transação e com uma garantia auditada nos próprios scripts: nenhuma informação futura entra na seleção. O primeiro executa a tese da forma mais direta possível: ao fim de cada mês, compra em pesos iguais as 10 empresas de maior TD, com base na call mais recente dos três meses anteriores, carrega a posição por um mês, rebalanceia e paga 10 pontos-base por lado sobre o giro. O segundo é um long-short por quintis, que compra o quinto de maior TD e vende o quinto de menor, em formato calendar-time com tranches sobrepostas e especificação congelada antes da execução (entrada no pregão seguinte à call, manutenção de 63 pregões, ranking contra os 90 dias anteriores, custos de 5 pontos-base por perna, amostra de 2006 a 2025).

Por fim, cabe registrar que todos os números do relatório saem de scripts versionados no repositório público. Qualquer avaliador reproduz as regressões e os backtests com quatro comandos, sem reprocessar transcrições; o procedimento foi testado em clone limpo e os números saíram idênticos.

5. Resultados econométricos

Antes das regressões, verificou-se se a base reconstruída é comparável à da literatura. A distribuição da TD calculada (média 0,0086, mediana 0,0080, desvio 0,0047) fica próxima da referência (0,0079, 0,0074, 0,0048), e os controles batem com os publicados: alavancagem de 0,24 contra 0,235, alíquota efetiva mediana de 0,22 contra 0,21 e suavização de lucros de 1,6 contra 1,4. O ponto de partida, portanto, é comparável.

5.1 H1, precificação no anúncio: confirmada

Se a divergência de tom revela informação negativa, o retorno anormal do anúncio deve cair com a TD, tudo o mais constante. A tabela reporta as estatísticas t do coeficiente da TD sobre o CAR nas três janelas de evento, para as três construções do sinal e os dois medidores (amostra de 2009 em diante, cerca de 23 mil eventos e 540 empresas). Cada célula responde à mesma pergunta: medindo desta forma, a divergência derruba o retorno do anúncio?

construção do sinal	LM (dicionário)	FinBERT (neural)
centro = média simples	-0,7 / -0,6 / -0,3	+0,1 / -0,2 / -0,5
centro = tom agregado	-2,0 / -2,1 / -1,7	-1,9 / -2,3 / -2,3
ponderada pelo volume de fala	-2,9 / -2,7 / -2,3	-2,4 / -2,4 / -2,5

(t nas janelas de 1, 2 e 5 pregões. Em termos econômicos, pular do quartil inferior ao superior da TD custa entre 0,11% e 0,16% de retorno anormal no anúncio.)

A hipótese se confirma na amostra completa sempre que o sinal respeita o volume de fala de cada gestor, como mostram as duas últimas linhas, significativas em todas as janelas. Além disso, o enfraquecimento é gradual de baixo para cima, ou seja, quanto mais peso se dá ao ruído dos oradores marginais, mais o sinal se dilui, exatamente como antecipado na Seção 3. Por fim, as colunas se espelham: dois medidores que concordam entre si em apenas 38% chegam ao mesmo desenho, o que enfraquece bastante a explicação por artefato de instrumento.

5.2 Retornos subsequentes: confirmados

O efeito, contudo, não termina no anúncio. Em painel mensal, o retorno dos três meses seguintes à call foi regredido contra a TD, com efeitos fixos de empresa e mês e controles de valor, momentum, tamanho e reversão, e o coeficiente saiu positivo nos dois medidores ($t=+2,1$ no dicionário e $+1,8$ no FinBERT). Em conjunto com a H1, o desenho se fecha de forma economicamente coerente: o mercado penaliza a empresa divergente no momento do anúncio e passa a exigir retorno maior para carregá-la nos meses seguintes, configurando o padrão clássico de compensação por risco.

5.3 H3, incerteza operacional: confirmada

Se a divergência reflete incerteza interna sobre o negócio, ela deve antecipar surpresas de lucro maiores, em qualquer direção, razão pela qual a variável testada é o valor absoluto da surpresa. No painel completo, o coeficiente da TD é positivo ($t=+2,2$). Ademais, no exercício de previsão fora da amostra, em que o modelo é treinado apenas com o passado e tenta prever eventos que nunca viu, a relação alcança $t=+3,58$, com acerto direcional em 71% dos trimestres, o que faz deste o resultado preditivo mais forte do projeto. Em linguagem de mesa: a divergência de hoje avisa que o próximo balanço tende a vir com surpresa grande.

5.4 H2, risco: descartada como sinal

O caminho até o descarte merece ser contado, pois ilustra o método. Na amostra completa, existe associação entre TD e volatilidade futura ($t=+2,5$ no dicionário). Entretanto, a investigação revelou um problema de medição: janelas de volatilidade que começam no dia seguinte ao anúncio ainda carregam a reação ao próprio anúncio, e empresas de TD alta reagem mais, o que é justamente a H1. Quando a volatilidade é medida a partir do segundo dia, fora desse eco, a associação perde significância ($t=+1,3$). Diante disso, foram rodadas 16 especificações predefinidas, combinando a presença ou não do eco, dois horizontes, nível e logaritmo e as duas construções do sinal, e nenhuma delas mostrou poder de previsão. Conclui-se que a TD não informa sobre risco futuro nada que a volatilidade passada já não diga, e o canal foi retirado do conjunto de sinais. Permanece verdadeira, como descrição, a constatação de que empresas de TD alta são em média mais voláteis, e esse fato retorna na interpretação do backtest.

5.5 Robustez e estabilidade temporal

Um resultado de amostra completa pode, em tese, ser fruto de um único subperíodo favorável. Para verificar essa possibilidade, as estimações foram refeitas usando apenas os dados disponíveis até cada data de corte, com conferência no período posterior, além da previsão por evento fora da amostra já descrita. O coeficiente da H1 mantém o sinal negativo em todos os cortes analisados, e a previsão fora da amostra confirma o efeito ($t=-2,12$, negativo em cada um dos anos de 2019 a 2025).

Da mesma forma, a camada de retornos subsequentes mantém coeficiente positivo em todos os cortes, e a H3 sustenta o $t=+3,58$ citado. Nos primeiros anos, com menos dados acumulados, os intervalos de confiança são naturalmente mais largos, comportamento esperado de um efeito estável estimado com precisão crescente. A exceção é a H2, reprovada nesses mesmos exercícios ($t=+0,27$), o que motivou o descarte. Cabe destacar, por fim, que o mesmo protocolo que valida duas hipóteses reprovava a terceira, o que dá confiança de que o critério não é complacente.

6. Backtest

A implementação principal executa a tese da forma que um gestor reconheceria: carteira comprada, regra fixa e rebalanceamento mensal. Para a leitura das tabelas, o índice de Sharpe é o retorno em excesso por unidade de volatilidade (quanto maior, melhor o retorno ajustado a risco), e o drawdown máximo é a maior queda acumulada do valor da carteira no período. Os números cobrem 199 meses, de fevereiro de 2009 a agosto de 2025:

	Top-10 TD bruto	Top-10 TD líquido	Bottom-10 TD	Universo elegível EW	S&P 500
Retorno acumulado	+2.061%	+1.783%	+959%	+1.208%	+682%
Retorno ao ano	+20,4%	+19,4%	+15,3%	+16,8%	+13,2%
Volatilidade a.a.	20,6%	20,6%	17,4%	17,3%	14,9%
Sharpe	1,01	0,96	0,91	0,99	0,91
Drawdown máximo	-29%	-29%	-27%	-27%	-25%

ano	top-10 TD	bottom-10	universo EW	S&P 500
2009	+113,1%	+44,6%	+61,3%	+35,0%
2010	+19,2%	+10,1%	+23,1%	+12,8%
2011	+4,8%	+8,6%	+0,5%	-0,0%
2012	+39,3%	+24,6%	+20,2%	+13,4%
2013	+30,5%	+53,1%	+37,8%	+29,6%
2014	+10,3%	+5,8%	+15,6%	+11,4%
2015	+5,9%	+6,8%	-1,5%	-0,7%
2016	+6,2%	+15,5%	+17,6%	+9,5%
2017	+18,2%	+12,8%	+21,6%	+19,4%
2018	+0,4%	-14,5%	-7,2%	-6,2%
2019	+44,5%	+27,1%	+31,5%	+28,9%
2020	+11,8%	+2,7%	+15,8%	+16,3%
2021	+20,0%	+23,4%	+31,3%	+26,9%
2022	-14,1%	-0,4%	-10,4%	-19,4%
2023	+37,6%	+14,7%	+17,8%	+24,2%
2024	+18,9%	+19,5%	+15,2%	+23,3%
2025*	+11,2%	+16,2%	+7,5%	+9,8%

(2025 até agosto. Giro médio de 34% ao mês. As composições são verificáveis; agosto de 2025, por exemplo: HII, MCD, CAH, ES, MCK, MTCH, CSCO, ANET, PODD, ABNB. Séries e composições completas em [data/interim/sp500/port10_.csv](#); replicação por [scripts/sp500_port10.py](#).)

A leitura desses números foi feita em duas camadas. Contra o S&P 500, o excesso é de +7,1% ao ano com $t=2,60$, com vitória em 58% dos meses e em 13 dos 17 anos, sendo este o número de manchete da estratégia. Contudo, um leitor técnico notará uma sutileza: carteiras de pesos iguais tendem a superar índices ponderados por valor simplesmente por darem mais espaço a empresas menores. Para isolar o mérito da seleção, construiu-se a régua mais exigente disponível, o próprio universo elegível em pesos iguais. Contra essa régua, a TD adiciona +3,6% ao ano ($t=1,59$), com contribuição positiva em todos os subperíodos analisados (+1,8% de 2010 em diante, +1,9% de 2015 em diante e +2,6% de 2019 em diante), embora sem significância isolada. Essa ausência de significância tem explicação mecânica, uma vez que, com apenas 10 ativos, o ruído específico de cada nome domina a variância da carteira e dilui um efeito que o painel estima em cerca de 15 pontos-base por variação interquartil. Em paralelo, a carteira espelho, composta pelas 10 empresas de menor TD, rende +15,3% ao ano, 5,1 pontos abaixo do top-10, na direção prevista pela tese.

Ademais, a tabela anual permite identificar os cenários favoráveis e desfavoráveis à estratégia. O top-10 destaca-se em anos de estresse ou de recuperação, como 2009, 2012, 2018, 2019 e 2023, chegando a fechar 2018 em alta de 0,4% enquanto o índice caía 6,2%, e a cair menos que o S&P 500 em 2022 (-14,1% contra -19,4%). Em contrapartida, a carteira fica para trás nos anos de alta ampla do mercado, como 2016 e 2021, quando concentrar em 10 nomes rende menos do que carregar o universo inteiro.

O long-short por quintis, por sua vez, não monetiza. Na especificação congelada, os retornos líquidos anualizados ficam entre +0,3% e +4,4% conforme a construção, com o melhor Sharpe em 0,22, estatisticamente nulo, contra 0,53 do mercado no período. O diagnóstico de pernas explica o motivo: a correlação entre a ponta comprada e a vendida é de apenas 0,6, e o quintil alto do sinal FinBERT carrega exposição a ações de baixa volatilidade, ou seja, um fator de risco conhecido, e não tom. As 6 construções testadas foram registradas e entram na contagem de tentativas para o ajuste de múltiplos testes (Deflated Sharpe, Bailey e López de Prado, 2014) na entrega final.

O perfil de risco fecha a interpretação. O top-10 realiza volatilidade maior que todas as régua (20,6% contra 17,3% a 17,4%) e Sharpe parecido com o do universo (1,01 contra 0,99), o que indica que o retorno extra remunera risco extra: trata-se de um prêmio de compensação por carregar as empresas cuja diretoria diverge, coerente com a associação descritiva da Seção 5.4, e não de uma anomalia gratuita. Dessa forma, a evidência sustenta quatro usos práticos para uma mesa: o tilt direcional sobre um portfólio core; o condicionamento de exposição em torno de anúncios, já que o score fica pronto minutos após cada call; o posicionamento de volatilidade no próximo anúncio das empresas de divergência alta, apoiado na previsão de surpresa de lucro; e o uso como insumo em um arcabouço multifator, cuja engenharia é o objeto da entrega final.

7. Riscos e limitações

Como toda pesquisa empírica, este trabalho possui limitações que merecem registro. A primeira diz respeito aos papéis de orador, que foram reconstruídos por um classificador próprio com cerca de 90% de acerto validado. As bases comerciais curadas utilizadas na literatura não têm esse ruído, e parte da diferença de magnitude entre as estatísticas aqui reportadas e as publicadas pode ter origem nesse ponto.

Ademais, algumas variáveis dependem de proxies. A surpresa de lucro vem do Yahoo Finance, e não do consenso I/B/E/S, e dois controles presentes na literatura, a participação institucional e a

qualidade de accruals, não foram reconstruídos, embora os outros 17 tenham sido. Na mesma linha, cerca de 3,4 mil eventos ficaram sem retorno anormal por falta de preços de empresas deslistadas em fonte gratuita, o que configura uma limitação de sobrevivência que preferimos declarar a esconder.

No campo da implementação, o efeito no anúncio, da ordem de 0,15% por variação interquartil, não paga custos como estratégia isolada de arbitragem do evento em large caps, razão pela qual a proposta se concentra em tilt, condicionamento e volatilidade. Além disso, com apenas 10 ativos, o excesso sobre o universo em pesos iguais é consistente, mas não significativo isoladamente, de modo que diversificar além de 10 nomes é o caminho natural da entrega final.

Por fim, a definição do centro da call admite duas construções na literatura. Ambas foram reportadas, e a escolha da agregada não foi guiada por resultado, e sim pela evidência textual da referência e pelo diagnóstico de ruído apresentado na Seção 3.

8. Conclusão e tese de investimento

O presente trabalho teve como objetivo verificar se a divergência de tom entre os gestores de uma mesma earnings call constitui informação precificada e, em caso positivo, se ela pode ser transformada em estratégia de investimento. As evidências apontam que sim. O fenômeno foi confirmado em universo independente, com dados públicos e código próprio, sobreviveu à troca completa do medidor de tom e se materializou em uma estratégia implementável, com custos e auditoria de ausência de informação futura.

A tese de investimento cabe em um parágrafo. A divergência de tom entre os executivos na earnings call é informação precificada em dois tempos. No anúncio, o mercado penaliza a empresa cuja diretoria diverge, um efeito condicional negativo e estável no tempo. Nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação: a carteira das 10 maiores TD rendeu +20,4% ao ano contra +13,2% do S&P 500 em 16 anos e meio, remunerando o risco adicional que o próprio sinal identifica. Além disso, o mesmo score antecipa a magnitude da surpresa do lucro seguinte, servindo de termômetro de incerteza antes de cada anúncio. A implementação recomendada combina tilt direcional, condicionamento de exposição a eventos e posicionamento de volatilidade, com a integração multifator como objeto da entrega final.

Cabe ainda registrar a fronteira que não avançou. O sinal foi testado em 2.250 firmas fora do S&P 500 (2019 a 2023), com especificações congeladas por pré-registro antes de qualquer resultado (docs/PREREG_MF.md, com data registrada em git). O painel resultou inconclusivo por falta de potência estatística, com coeficientes positivos, não significativos, janela curta e cobertura de preços de 69%. Entretanto, no mesmo período, o efeito segue presente nas large caps ($t=-1,96$), o que aponta a causa para o universo e a qualidade dos dados, e não para a época. A fronteira permanece documentada e não é apresentada como resultado.

Até a entrega final (17/08), a agenda contempla três itens: o desenho da integração multifator do score, com contagem de tentativas e Deflated Sharpe; a robustez final de custos e a análise de decaimento do sinal; e, havendo dados de preços de deslistadas, a revisita à fronteira de small e mid caps com o pré-registro já versionado.

Encerra-se com uma nota de método. Em amostra completa, as três hipóteses pareciam confirmadas, e foram os exercícios de robustez temporal que separaram os efeitos reais

(precificação, retornos subsequentes e incerteza operacional) do artefato (risco). Esse protocolo, aplicado sem exceção e documentado no repositório, é parte central do que a equipe leva para a entrega final.

9. Uso de IA generativa no processo

O uso de GenAI neste trabalho é operacional e auditável, não declaratório. No núcleo do pipeline, um processo por linha de comando (claude -p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes, com cache versionado e reprocessamento determinístico, em cerca de 4,6 horas de execução. A validação usou matriz de confusão contra 292 rótulos manuais, com cerca de 90% de acerto global, além de um classificador determinístico independente para comparação, com 99% de concordância nos casos frequentes; prompt, custos e validação estão documentados em docs/GENAI_USAGE.md. Ao longo de todo o processo, o assistente (Claude) atuou como par de engenharia e auditoria, apoiando a arquitetura do pipeline, o código, os testes, a documentação e, com impacto direto no resultado, a auditoria da fórmula do centro da call, sempre com as decisões econômicas e metodológicas a cargo da equipe. Por fim, vale uma distinção conceitual: o FinBERT é um modelo de linguagem do tipo encoder, parte do modelo quantitativo, permitido pelo edital, mas contabilizado como NLP/ML, e não como IA generativa.

Referências

- Angelo, Johnston, Singh e Wan (2025). Tone Distance: Managerial Tone Divergence and Market Reaction to Earnings. *The Financial Review*.
- Bailey, D. H., e López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5).
- Fama, E. F., e French, K. R. (1997). Industry Costs of Equity. *Journal of Financial Economics*, 43(2).
- Huang, X., Teoh, S. H., e Zhang, Y. (2014). Tone Management. *The Accounting Review*, 89(3).
- Lee, J. (2016). Can Investors Detect Managers' Lack of Spontaneity? Adherence to Predetermined Scripts during Earnings Conference Calls. *The Accounting Review*, 91(1).
- Loughran, T., e McDonald, B. (2011). When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 66(1).
- Yang, Y., Uy, M. C. S., e Huang, A. (2020). FinBERT: A Pretrained Language Model for Financial Communications. arXiv:2006.08097.

Todos os números deste relatório saem de scripts versionados no repositório e foram reproduzidos em clone limpo. Nenhum número foi digitado à mão.