

# CORO — Divergência de tom entre gestores como sinal quantitativo

Pré-relatório · Desafio Quant AI 2026 (Itaú Asset)

Equipe: Marcelo e Caio · Orientação: Profa. Nadia Cardoso Moreira

Repositório (código + dados derivados + replicação em 4 comandos):

<https://github.com/marceleann/Caio-e-Marcelo-e-Vinicius>

[NOME A CONFIRMAR PELO TIME] Em avaliação: **DESAFINADO** ("quando a diretoria desafina, o mercado ouve"), **DISSONA**, **OUVIDOR** ou **CORO**. Qualquer que seja a escolha, o nome resume a tese em uma imagem: não medimos o tom médio da empresa, e sim o desalinhamento entre as vozes que a representam.

---

## Resumo executivo — a história em uma página

**O ponto de partida.** Numa teleconferência de resultados, a empresa ensaia uma mensagem única — mas várias vozes a entregam: CEO, CFO, diretores. A tese deste trabalho é que, quando essas vozes desafinam entre si, isso é informação: desacordo interno e incerteza que a mensagem oficial tenta uniformizar, mas que o Q&A ao vivo não deixa esconder. Essa divergência tem medida (a **Tone Distance** de Angelo et al., 2025) e, mostramos, tem preço. Replicamos o artigo do zero no S&P 500 — 33.362 calls, 685 empresas, 2005–2025, dados 100% públicos — com uma única inovação deliberada: um segundo medidor de tom, o modelo neural FinBERT, ao lado do dicionário Loughran-McDonald do artigo.

**O que encontramos, em três atos.** *Primeiro:* a hipótese central replica — o mercado penaliza no anúncio a empresa cujos gestores divergem (t até -2,9, e o resultado sobrevive à troca completa do sensor de tom). No caminho, um achado próprio: a fórmula do artigo admite duas leituras, e diagnosticar qual delas separa sinal de ruído (o peso de fala de cada gestor) virou contribuição metodológica. *Segundo:* a tese vira carteira — comprar todo mês as 10 empresas de maior Tone Distance rendeu **+20,4% ao ano contra +13,2% do S&P 500** em 16 anos e meio (excesso com  $t=2,60$ ), com a leitura honesta de que parte disso é o equal-weight e o tilt próprio da seleção (+3,6% a.a. sobre o universo equivalente) é consistente em todos os subperíodos, mas não significativo com só 10 nomes. *Terceiro:* o sinal prevê a **incerteza do próximo balanço** ( $t=+3,58$ , nosso resultado prospectivo mais forte) — divergência hoje antecipa surpresa de lucro grande no trimestre seguinte.

**O que o trabalho descarta — e por que isso vale tanto quanto o que valida.** Das três hipóteses do artigo, a de risco (H2) morre na validação temporal: verdadeira como descrição, vazia como sinal. O detalhe central: em amostra cheia, as **três** hipóteses pareciam confirmadas em 48 de 48 momentos testados — só separar passado de futuro distingue achado real de miragem estatística. Esse filtro, aplicado sem exceção, é o que sustenta cada número deste relatório; todos saem de scripts versionados num repositório público e se reproduzem em 4 comandos.

(As seções seguem os critérios do edital: identidade §1, conceito e hipóteses §2, dados e modelagem §3, resultados e validação §4, backtest e estratégia §5, análise crítica §6, conclusão §7, uso de GenAI §8.)

## 1. Identidade do robô

O CORO processa a transcrição de cada teleconferência de resultados (*earnings call*) e transforma uma pergunta qualitativa — "os executivos da empresa estão alinhados no que dizem?" — em um número: a **Tone Distance** (distância de tom), a dispersão do tom entre os gestores que falam na mesma call. A saída é objetiva e operacionalizável: um escore por empresa-trimestre, disponível minutos após a divulgação da transcrição, usável como sinal de seleção e como indicador de risco.

## 2. Conceito e hipótese (o fenômeno, a justificativa, o teste)

**Fenômeno.** Numa earnings call, a empresa ensaia uma mensagem única, mas vários executivos falam (CEO, CFO, diretores). Quando os tons deles divergem entre si, essa divergência pode revelar informação privada que a mensagem oficial tenta uniformizar: desacordo interno, incerteza sobre o trimestre, narrativas que não fecham.

**Justificativa econômica.** A literatura de *disclosure* mostra que o mercado extrai informação do que é mais difícil de gerenciar na comunicação (Huang et al. 2014; Lee 2016). A divergência entre gestores é cara de coordenar em tempo real no Q&A. Angelo, Johnston, Singh e Wan (2025, *The Financial Review*) formalizam a medida (Tone Distance) e documentam, em ~188 mil calls americanas: retorno anormal negativo no anúncio, risco futuro maior e retorno médio maior nos meses seguintes (compensação pelo risco revelado).

**Hipóteses testáveis** (as três do artigo, pré-registradas):

- **H1:** mais Tone Distance → retorno anormal (CAR) menor no anúncio;
- **H2:** mais Tone Distance → mais risco realizado após o anúncio;
- **H3:** mais Tone Distance → piora de resultados operacionais futuros.

**Como testamos.** Replicação fiel do desenho econométrico do artigo em universo, dados e código próprios — e, como contribuição, a mesma bateria com **dois sensores de tom independentes** (léxico Loughran-McDonald e o modelo neural FinBERT em nível de sentença), o que permite separar "achado real" de "artefato do medidor de tom".

## 3. Dados e modelagem

**Fluxo:** dados → modelo → decisão → teste.

| etapa   | conteúdo                                                                                                                                                                                                                     |
|---------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Entrada | 33.362 transcrições de earnings calls (S&P 500, 2005–2025, 685 empresas; dataset público kurry/HuggingFace)                                                                                                                  |
| Papéis  | cada fala é atribuída a gestor/analista/operador por classificador em dois níveis: <b>LLM via CLI</b> (12.678 cabeçalhos) + regras determinísticas; validado com matriz de confusão (~90% de acerto contra rotulagem manual) |
| Tom     | dois sensores: contagem de palavras positivas/negativas do dicionário Loughran-McDonald oficial; e FinBERT (finbert-tone) sentença a sentença                                                                                |

|       |                                                                                                                                                                              |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Sinal | <b>Tone Distance</b> (Eq. 1 de Angelo): cada gestor vira um ponto (fração positiva, fração negativa); TD = distância média dos gestores ao centro da call; mínimo 2 gestores |
| Saída | escore por call + variantes (centroide agregado; ponderação pelo volume de fala)                                                                                             |
| Teste | painel com efeitos fixos de empresa e ano-trimestre, erros agrupados por empresa, winsorização 5/95 — a Eq. (3) do artigo — mais backtest calendar-time próprio              |

**Retornos anormais (CAR)** calculados como no artigo, conferido no texto: CAPM estimado em janela de 100 pregões (mínimo 70) com intervalo de 50 antes do evento; janelas de evento [-1,+1], [-1,+2], [-1,+5] no dia do anúncio. **Controles** reconstruídos de fontes primárias: fundamentos trimestrais do SEC EDGAR (XBRL, alinhados pela data de protocolo — sem *look-ahead*), indústria Fama-French 49 via código SIC de cada CIK, surpresa de lucro (proxy yfinance), taxa livre de risco de Ken French.

**Replicabilidade** (critério explícito do desafio): repositório público com código, documentação e **dados derivados versionados**; qualquer avaliador reproduz as regressões com 4 comandos, sem reprocessamento. Testado por nós em clone limpo: números idênticos.

**Um achado de modelagem que virou contribuição.** A fórmula do centro da call no artigo admite duas leituras: (A) média simples das frações dos gestores; (B) fração agregada (o "tom do transcript"). Implementamos as duas. Na leitura A, um orador marginal desloca o centro — caso real: na call da Apple de 2020, o profissional de relações com investidores falou 283 palavras, das quais 6 "negativas" pelo dicionário eram o aviso legal padrão (*risks, uncertainties*), e esse ponto respondia por um terço do peso do sinal. A leitura B (e, além dela, a ponderação pelo volume de fala, que o próprio artigo propõe na Tabela 8) elimina essa contaminação. Verificamos a implementação com reimplementação independente nas 32.387 calls (diferença máxima  $8 \times 10^{-17}$ ) e exemplo auditável à mão.

## 4. Resultados

**Validação da construção.** Nossa TD tem distribuição quase idêntica à do artigo (média/mediana/desvio 0,0086/0,0080/0,0047 vs 0,0079/0,0074/0,0048), e os controles reconstruídos batem com a Tabela 1 dele (alavancagem 0,24 vs 0,235; ETR mediana 0,22 vs 0,21; suavização 1,6 vs 1,4).

**H1 — o resultado central, em dois sensores.** Efeito da TD sobre o CAR do anúncio (painel com efeitos fixos; estatística t; amostra 2009+, ~23 mil eventos, ~540 empresas):

| construção do sinal                                   | LM (dicionário)    | FinBERT (neural)   |
|-------------------------------------------------------|--------------------|--------------------|
| centro = média simples (leitura A)                    | -0,7 / -0,6 / -0,3 | +0,1 / -0,2 / -0,5 |
| centro = tom agregado (leitura B)                     | -2,0 / -2,1 / -1,7 | -1,9 / -2,3 / -2,3 |
| ponderada pelo volume de fala<br>(Tabela 8 do artigo) | -2,9 / -2,7 / -2,3 | -2,4 / -2,4 / -2,5 |

(t nas janelas [-1,+1] / [-1,+2] / [-1,+5]; efeito econômico: uma variação interquartil de TD  $\approx$  **-0,11% a -0,16%** de CAR, contra -0,21% no artigo.)

Três leituras desta tabela: (i) a hipótese H1 do artigo **replica** no S&P 500 quando o sinal respeita o volume de fala de cada gestor; (ii) a progressão é monotônica — quanto mais peso ao ruído dos oradores marginais, mais fraco o sinal — o que diagnostica com precisão por que a versão igual-ponderada falha em large caps; (iii) os dois sensores, que concordam entre si em apenas 38% (correlação), produzem o mesmo quadro — o achado não é artefato do medidor de tom.

**H2 — risco: associação em amostra cheia que NÃO sobrevive à validação temporal.** Na amostra completa, a TD ponderada associa-se a volatilidade futura ( $t = +2,5$  no sensor LM; nada no FinBERT). Mas o teste walk-forward (estimar só com o passado em cada corte anual e conferir no futuro não visto) reprovava o canal na nossa especificação; a investigação (auditoria da variável com recomputação independente — idêntica a 6 casas decimais — e decomposição de janelas) localizou a origem da divergência com o artigo: **a janela**. O artigo mede a vol a partir do dia +1 (ainda dentro da ressaca do anúncio); nós, do +2 (fora dela). Com a janela do artigo, a H2 replica em amostra cheia ( $t=+2,1$ ); com a janela limpa, não existe ( $t=+1,3$ ); e a diferença é o **eco mecânico do próprio anúncio** — empresas de TD alta têm reação maior (a H1), e janelas que encostam no evento herdavam essa turbulência. Prospectivamente, nem a janela do artigo sustenta (walk-forward: futuro na direção esperada em 28/48 momentos; previsão condicional  $t=+1,0$ ) — e a versão limpa falha por completo (0/48 no horizonte longo). **Caracterização final: a H2 se confirma como descrição e reprovava como sinal.** Empresas de TD alta são, de fato, mais voláteis — na carteira executada do §5, o top-10 escolhido sempre *antes* do mês realiza vol de 20,6% contra 17,4% do bottom-10 —, mas essa é uma informação que a própria volatilidade passada já entrega de graça: exigida a prever algo *além* dela e dos controles, a TD fica muda em todas as 16 células pré-especificadas que testamos. E até a versão descritiva está em extinção: o gap de vol entre top-10 e bottom-10 cai de 6,1 p.p. (2009–14) para 1,2 p.p. (2015–25) — a mesma data de morte que o walk-forward condicional havia apontado, agora confirmada por um método totalmente independente. O "canal de risco" é sobretudo o prolongamento da reação ao anúncio, já contado na H1; não o usamos como sinal — mas ele sobrevive como **explicação econômica do prêmio** da carteira: quem carrega as empresas de TD alta ganha mais correndo mais risco (§5), compensação, não almoço grátis.

**H3 — operacional.** O valor absoluto da surpresa de lucro seguinte aumenta com a TD ( $t = +2,2$  na amostra ampla), com a mesma concentração de regime.

**Retornos subsequentes (Tabela 6 do artigo).** Painel mensal (retorno dos 3 meses após a call; efeitos fixos de empresa e mês; controles de valor, momentum, tamanho e reversão): coeficiente positivo nos dois sensores ( $t = +2,1$  LM;  $+1,8$  FinBERT; artigo:  $+2,2$ ) — consistente com o mecanismo do artigo: o mercado penaliza no anúncio e exige retorno maior depois. Validação walk-forward desta camada (cortes anuais 2014–2022):  $\beta$  futuro **positivo em 9 de 9 cortes** para a versão ponderada, com significância nos futuros longos ( $t$  até  $+2,5$ ) — e duas ressalvas declaradas: o lado passado só ganha significância a partir de 2019, e os futuros dos cortes recentes são curtos ( $t < 1$ ). Leitura: prêmio direcionalmente estável em todos os momentos, força moderada.

**Validação temporal (matriz completa: 3 tipos de teste  $\times$  3 hipóteses, todos os resultados reportados, inclusive os contrários).**

| teste                                     | H1 (CAR)                                             | H2 (vol)                                                                     | H3 ( SUE )                 |
|-------------------------------------------|------------------------------------------------------|------------------------------------------------------------------------------|----------------------------|
| 1. carteira / realização<br>calendar-time | quintis L-S nulos (melhor<br>Sharpe 0,22, $t=0,99$ ) | vol da cesta alta – baixa:<br>+0,4 a +2pp sobre ~33%<br>(sem valor prático); | cesta trimestral = teste 3 |

|                                                                                                                    |                                                   | FinBERT invertida (-11pp) |                                                   |
|--------------------------------------------------------------------------------------------------------------------|---------------------------------------------------|---------------------------|---------------------------------------------------|
| 2a. walk-forward anual do $\beta$ condicional                                                                      | 10/12                                             | <b>3/12</b>               | 9/12                                              |
| 2b. walk-forward TRIMESTRAL (48 momentos) — passado / futuro na direção da hipótese                                | 48/48 · <b>40/48</b>                              | 48/48 · <b>15/48</b>      | 48/48 · 32/48                                     |
| 3. previsão por evento sem controles (50 trimestres à parte)                                                       | 42% de acerto                                     | 58%                       | 35%                                               |
| 4. previsão por evento <b>condicional</b> (resíduo do modelo treinado no passado; o teste que casa com a hipótese) | <b>62% · spread -0,14% · <math>t=-2,12</math></b> | 52% · $t=+0,27$           | <b>71% · spread +0,74% · <math>t=+3,58</math></b> |

Duas lições estruturam a leitura. **Primeira (linha 2b):** nas três hipóteses, o  $\beta$  estimado com o passado aponta a direção "esperada" em 48 de 48 momentos — em amostra corrente, as três pareceriam confirmadas. Só o futuro as separa: H2 é contrariada em 69% dos momentos (canal extinto após ~2014) e é descartada; H1 e H3 sobrevivem. **Segunda (linhas 3 vs 4): o teste precisa casar com a afirmação.** A versão incondicional (ordenar empresas cruamente por TD) não prevê nada, porque mistura o sinal com características de firma; quando a previsão usa o modelo condicional treinado só no passado (resíduos), a H1 valida por evento fora da amostra ( $t=-2,12$ ; spread negativo em todos os anos desde 2019) e a H3 entrega o resultado prospectivo mais forte do projeto ( $t=+3,58$ ; 71% dos trimestres): divergência de tom hoje prevê imprevisibilidade do lucro do trimestre seguinte. Registro de método: a linha 4 não estava no desenho original — nasceu da revisão interna; o que a defende é ser o teste teoricamente correto da afirmação condicional, e o fato de reprovar a H2 junto (um teste complacente não reprovaria). (Nota: cortes adjacentes compartilham dados; as contagens medem estabilidade, não testes independentes.)

## 5. Backtest e estratégia

### 5.1 A tese executada: carteira das 10 maiores TD, mês a mês

O teste mais concreto que uma tese de investimento admite: **comprá-la**. No fechamento de cada mês, a carteira compra em pesos iguais as **10 empresas de maior Tone Distance** (call mais recente dos 3 meses anteriores), segura o mês seguinte e rebalanceia. A seleção usa apenas informação disponível na data (auditado mês a mês pelo próprio script: nenhuma call usada é posterior ao início do mês investido); custos de 10 pontos-base por lado sobre o turnover realizado (34%/mês). 199 meses, de fev/2009 a ago/2025:

|                   | Top-10 TD bruto | Top-10 TD líquido | Bottom-10 TD | Universo elegível EW | S&P 500 |
|-------------------|-----------------|-------------------|--------------|----------------------|---------|
| Retorno acumulado | <b>+2.061%</b>  | +1.783%           | +959%        | +1.208%              | +682%   |
| Retorno ao ano    | <b>+20,4%</b>   | +19,4%            | +15,3%       | +16,8%               | +13,2%  |
| Volatilidade a.a. | 20,6%           | 20,6%             | 17,4%        | 17,3%                | 14,9%   |

|                 |      |      |      |      |      |
|-----------------|------|------|------|------|------|
| Sharpe          | 1,01 | 0,96 | 0,91 | 0,99 | 0,91 |
| Drawdown máximo | −29% | −29% | −27% | −27% | −25% |

| ano   | top-10 TD | bottom-10 | universo EW | S&P 500 |
|-------|-----------|-----------|-------------|---------|
| 2009  | +113,1%   | +44,6%    | +61,3%      | +35,0%  |
| 2010  | +19,2%    | +10,1%    | +23,1%      | +12,8%  |
| 2011  | +4,8%     | +8,6%     | +0,5%       | −0,0%   |
| 2012  | +39,3%    | +24,6%    | +20,2%      | +13,4%  |
| 2013  | +30,5%    | +53,1%    | +37,8%      | +29,6%  |
| 2014  | +10,3%    | +5,8%     | +15,6%      | +11,4%  |
| 2015  | +5,9%     | +6,8%     | −1,5%       | −0,7%   |
| 2016  | +6,2%     | +15,5%    | +17,6%      | +9,5%   |
| 2017  | +18,2%    | +12,8%    | +21,6%      | +19,4%  |
| 2018  | +0,4%     | −14,5%    | −7,2%       | −6,2%   |
| 2019  | +44,5%    | +27,1%    | +31,5%      | +28,9%  |
| 2020  | +11,8%    | +2,7%     | +15,8%      | +16,3%  |
| 2021  | +20,0%    | +23,4%    | +31,3%      | +26,9%  |
| 2022  | −14,1%    | −0,4%     | −10,4%      | −19,4%  |
| 2023  | +37,6%    | +14,7%    | +17,8%      | +24,2%  |
| 2024  | +18,9%    | +19,5%    | +15,2%      | +23,3%  |
| 2025* | +11,2%    | +16,2%    | +7,5%       | +9,8%   |

(2025 até agosto. Composições conferíveis à mão: p.ex. ago/2025 = HII, MCD, CAH, ES, MCK, MTCH, CSCQ, ANET, PODD, ABNB.)

**Como ler estes números com honestidade** — é aqui que o trabalho se separa de um backtest de folheto. O excesso sobre o S&P 500 é **+7,1% a.a. (t=2,60)**, com vitória em 58% dos meses e em 13 dos 17 anos. Mas a régua justa para uma carteira equal-weight não é um índice ponderado por valor, e sim o universo elegível equal-weight: contra ele, a seleção por TD adiciona **+3,6% a.a. (t=1,59)** — positivo em todos os subperíodos testados (2010+: +1,8%; 2015+: +1,9%; 2019+: +2,6% a.a.), porém nunca significativo. Ou seja: cerca de metade do excesso sobre o índice vem do equal-weight em si, e o tilt próprio da TD, embora consistente, dilui-se no ruído de uma carteira de só 10 nomes — exatamente o que o efeito pequeno do painel (§4) prevê. O Sharpe praticamente igual ao do universo (1,01 vs 0,99) diz o resto: o retorno extra vem acompanhado de risco extra — compensação por carregar as empresas mais tensas, a leitura econômica do próprio artigo, não almoço grátis. A variante ponderada por palavras, melhor no painel, empata com o universo na cauda extrema de 10 nomes (com 10 ativos, o ranking simples captura melhor a ponta da distribuição). Séries mensais e composições em `data/interim/sp500/port10_*.csv`; replicável por `scripts/sp500_port10.py`.

## 5.2 Quintis long-short calendar-time (especificação congelada)

**Especificação congelada antes de rodar** (contra viés de escolha): carteira calendar-time com tranches sobrepostas; entrada no fechamento do pregão seguinte à call (T+1); manutenção de 63 pregões; ranking point-in-time do sinal contra os 90 dias anteriores; quintis extremos (long TD alta / short TD baixa — direção fixada a priori pelo artigo); custos de 5 pontos-base por perna; amostra completa 2006–2025 sem seleção de período; benchmark S&P 500.

**Resultados líquidos** (long-short anualizado, todas as construções do sinal sob a mesma especificação; 6 tentativas contadas para o Deflated Sharpe): leitura A +2,0% a.a. (Sharpe 0,18); **leitura B +2,4% (Sharpe 0,22, o melhor — e ainda assim  $t(\text{Sharpe})=0,99$ , não significativo)**; ponderada +0,3% (0,05); FinBERT ponderada +4,4% (0,17) — com a ressalva de que o diagnóstico de pernas mostra correlação de só 0,6 entre long e short: o quintil alto de FinBERT embute aposta em ações de baixa volatilidade, um fator, não tom; histórico próprio +0,6% (0,07). Mercado no período: Sharpe 0,53. Nenhuma construção monetiza em quintis long-short.

### 5.3 O que a estratégia pode (e não pode) prometer

A bateria completa de implementação — carteira executada (5.1), quintis long-short (5.2), previsão por evento em todos os momentos, out-of-sample 2023–25 — converge num veredito único: **ordenar ações por TD gera um tilt comprado direcional e consistente, mas não alpha estatisticamente demonstrável contra a régua justa em large caps**. O prêmio identificado no painel é condicional (dentro da empresa, com controles), pequeno (~15 bps por variação interquartil) e, no corte cruzado, disputa espaço com características de firma (diagnóstico explícito: o quintil alto do sinal FinBERT embute aposta em baixa volatilidade — correlação entre pernas de só 0,6).

O CORO é portanto apresentado pelo que a evidência sustenta: um **motor de análise de eventos** cujo score, minutos após cada call, carrega dois conteúdos validados prospectivamente por evento (teste condicional, linha 4 da matriz): (i) **precificação no anúncio** — resíduo de CAR menor para divergência alta ( $t=-2,12$ ; negativo todos os anos desde 2019); (ii) **incerteza do próximo lucro** — previsão da magnitude da surpresa do trimestre seguinte ( $t=+3,58$ , o resultado prospectivo mais forte do projeto). As aplicações coerentes com isso: condicionamento de exposição a eventos, posicionamento de volatilidade em torno do PRÓXIMO anúncio das empresas de divergência alta, e insumo num arcabouço multifator — não long-short isolado por ordenação crua (reprovado e explicado). A camada de retorno mensal também passou pela validação temporal ( $\beta$  futuro positivo em 9/9 cortes, força moderada — §4), sustentando a perna de tilt como direcional. A engenharia dessas aplicações é o trabalho da entrega final. Não há testes pendentes: toda afirmação deste relatório tem a sua validação executada e reportada.

**Vieses tratados:** sem escolha oportunista de período (2005–2025 tudo); execução T+1 com carimbo de hora da call (27% das calls pós-fechamento deslocadas para o pregão seguinte — teste feito, resultado robusto); sobrevivência: universo inclui 685 empresas históricas do índice, com a limitação declarada de que ~77 deslistadas ficam sem preços na fonte gratuita; custos incluídos; direção e janelas pré-fixadas pelo artigo (sem mineração de especificação).

## 6. Análise crítica e fragilidades (declaradas)

1. **Papéis de orador reconstruídos** (~90% de acerto validado). O dado curado (Capital IQ) do artigo não tem esse ruído; parte da diferença entre nossos  $t$  e os do artigo pode vir daí.
2. **Proxies:** surpresa de lucro via yfinance (não I/B/E/S); sem *institutional ownership* (13F) e qualidade de accruals entre os controles — os demais 17 controles do artigo foram reconstruídos.
3. **Sobrevivência parcial:** ~3,4 mil eventos sem CAR por falta de preços de deslistadas em fonte gratuita.



4. **Efeito pequeno:**  $-0,15\%$  por variação interquartil não paga custos como estratégia isolada de anúncio em large caps.
5. **Regime e validação temporal:** o canal de risco (H2) reprova como sinal incremental (extinto após ~2014, confirmado por dois métodos independentes — §4 e §5.1). H1 e H3 atravessam a validação temporal, mas cada um com sua ressalva: H1 só na forma condicional (não como ordenação crua) e H3, embora o resultado prospectivo mais forte no teste condicional ( $t=+3,58$ ), tem acerto direcional apenas moderado no corte trimestral (32/48). O prêmio de retorno mensal só ganha significância no passado a partir de 2019.
6. **Ambiguidade do artigo:** a definição do centroide tem duas leituras; reportamos as duas (a igualmente ponderada é nula; a agregada replica). Não escolhemos a leitura pelos resultados: a evidência textual do artigo (rótulo "Average Transcript Tone" da Figura 1) aponta para a agregada.

## 7. Conclusão e próximos passos

**O que o pré-relatório estabelece:** a divergência de tom entre gestores é informação precificada — replicamos o resultado central de Angelo (2025) em universo independente, com dados públicos, e mostramos que ele sobrevive à troca completa do medidor de tom (léxico → neural). A contribuição própria é dupla: o diagnóstico de *como* medir (o peso de fala separa sinal de ruído em calls com muitos participantes) e a infraestrutura 100% replicável.

### A tese de investimento, em um parágrafo:

A divergência de tom entre os gestores na earnings call é informação precificada em dois tempos. No anúncio, o mercado penaliza a empresa cuja diretoria desafina (CAR condicional negativo, validado ano a ano desde 2019). Nos meses seguintes, carregar as empresas de maior divergência captura um prêmio de compensação: a carteira executada das 10 maiores TD rendeu  $+20,4\%$  a.a. contra  $+13,2\%$  do S&P 500 em 16 anos e meio — retorno extra pago por risco extra, coerente com a leitura econômica do artigo. E o mesmo sinal prevê a magnitude da surpresa do **próximo** lucro ( $t=+3,58$ ), fazendo dele um termômetro de incerteza pré-anúncio. A promessa honesta: um tilt direcional consistente, cuja significância contra o universo equivalente pede diversificação maior que 10 nomes — um motor de eventos e de incerteza validado, não uma máquina de alpha isolada.

**Sobre a expansão small/mid caps (teste já realizado, pré-registrado):** testamos a tese de expansão num universo de 2.250 firmas fora do S&P 500 (dataset Motley Fool, 2019–2023), com hipóteses e especificações congeladas por pré-registro ANTES de qualquer resultado (docs/PREREG\_MF.md, timestamp em git). O painel não confirmou a hipótese: coeficientes positivos e não significativos, com intervalo de confiança que contém tanto o efeito do S&P quanto zero (inconclusivo por potência: janela de 3,5 anos, metade em 2021, CAR 60% mais volátil, cobertura de preços de 69% com viés de sobrevivência). O diagnóstico de reconciliação isolou a causa: no MESMO período 2019–23, o efeito segue presente nas large caps ( $t=-1,96$ ) — o problema é o universo ou a qualidade dos dados dele, não a época. A fronteira segue aberta e documentada; não a apresentamos como resultado.

### Próximos passos até a entrega final (17/08):

1. **Desenho da integração multifator** do score CORO (interações com fatores e regimes), com contagem honesta de tentativas e Deflated Sharpe;



2. Robustez final: sensibilidade a custos, análise de decay;
3. Se houver dados melhores (preços de deslistadas), visitar a fronteira small/mid com o pré-registro já commitado.

**A lição que organiza o trabalho.** Nas três hipóteses, o modelo estimado com o passado apontava a direção "esperada" em 48 de 48 momentos — em amostra cheia, as três pareceriam confirmadas, e um relatório escrito nesse ponto venderia uma miragem com convicção. Só a validação temporal separou o real (H1, H3, o prêmio mensal) do artefato (H2). Esse filtro — e a disposição de descartar um resultado bonito quando o futuro o desmente — é o principal produto deste pré-relatório, e é o que a equipe leva para a entrega final.

## 8. Uso de IA Generativa no processo

O uso de GenAI é **operacional e auditável**, não declaratório:

1. **Classificação de papéis por LLM (núcleo do pipeline).** Um robô por linha de comando (claude - p, modelo Haiku) classificou os 12.678 cabeçalhos de orador em lotes, com cache versionado e reprocessamento determinístico (~4,6h de execução). Validação: matriz de confusão contra 292 rótulos manuais (~90% de acerto global) e classificador determinístico independente para comparação (99% de concordância nos casos frequentes). Prompt, custos e validação documentados em docs/GENAI\_USAGE.md.
2. **Par de engenharia e auditoria (processo inteiro).** Arquitetura do pipeline, código, testes, documentação e — com impacto direto no resultado — a auditoria da fórmula do centroide: a reimplementação independente e o teste das duas leituras da Eq. (1) que mudaram a conclusão central foram conduzidos em par com o assistente (Claude), com decisões econômicas e metodológicas sempre da equipe.
3. **O que NÃO chamamos de GenAI:** o FinBERT é um modelo de linguagem *encoder* (classificação), parte do modelo quantitativo — permitido pelo edital, mas contabilizado como NLP/ML, não como IA generativa.

---

*Todos os números deste relatório saem de scripts versionados no repositório e foram reproduzidos em clone limpo. Nenhum número foi digitado à mão.*